

Übung: Erklärbare KI

(Bearbeitung in Einzel- oder Gruppenarbeit)

Zu der Übung stehen die folgenden Jupyter-Notebooks (Colab-tauglich) bereit:

- 01_LIME_SHAP_tabular.ipynb (Tabellarische Daten)
- 02_feature_importance.ipynb (Tabellarische Daten - Feature Importance)
- 03_LIME_nlp.ipynb (Text – Klassifikation)

1. **LIME-Grundprinzip (konzeptionell).** Erläutern Sie in eigenen Worten das Grundprinzip von LIME. Gehen Sie insbesondere auf folgende Punkte ein: (i) lokale Approximation, (ii) Perturbationen (*Nachbarschaftspunkte*) und (iii) Modellagnostizität. Nennen Sie außerdem eine Stärke und eine Schwäche von LIME.

2. **Notebook-Aufgabe LIME & SHAP für tabellarische Daten.**

Öffnen Sie 01_LIME_SHAP_tabular.ipynb in Google Colab und führen Sie das gesamte Notebook aus. Beantworten Sie anschließend:

- (a) Was ist der “UCI adult income dataset”? Was soll vorhergesagt werden? Was sind die Merkmale?
- (b) Welche Klasse wird für den Datenpunkt 0 des Testdatensatzes vorhergesagt? Was sind laut LIME die 2-3 wichtigsten Merkmale, die zu dieser Entscheidung geführt haben? Welche Werte haben diese? Macht es Sinn, dass diese Merkmale die wichtigsten sind und andere unwichtig?
- (c) Welche Klasse wird für den Datenpunkt 100 des Testdatensatzes vorhergesagt? Was sind laut LIME die 2-3 wichtigsten Merkmale, die zu dieser Entscheidung geführt haben? Welche Werte haben diese? Macht es Sinn, dass diese Merkmale die wichtigsten sind und andere unwichtig?
- (d) SHAP (WS 26/27): Welche drei Merkmale sind die wichtigsten laut SHAP?
- (e) (WS 26/27) Steigt das Jahreseinkommen mit dem Alter oder fällt es? Wie erkennen Sie das?
- (f) (WS 26/27) Vergleichen Sie die wichtigsten drei Features für Individuum 100 bei LIME und SHAP. Sind diese identisch oder unterscheiden sich diese?

3. **Feature Importance für Entscheidungsbäume.**

Öffnen Sie 02_feature_importance.ipynb in Google Colab. Beantworten Sie anschließend:

- (a) Was sind die wichtigsten drei Features bezüglich der Feature Importance?
- (b) Vergleichen Sie die Ergebnisse mit LIME. Was fällt auf?

4. **Notebook-Aufgabe LIME (Text).**

Öffnen Sie `03_LIME_nlp.ipynb` und führen Sie das Notebook vollständig aus. Beantworten Sie anschließend:

- (a) Was ist TF-IDF?
- (b) Welche drei Wörter haben die Vorhersage für den Text mit der ID 83 am stärksten beeinflusst? Wo stehen diese Wörter im Text? Haben die Wörter etwas mit der vorhergesagten Klasse zu tun? Welche Klasse wurde vorhergesagt?
- (c) Probieren Sie ein anderes Dokument aus dem Testdatensatz aus und berichten Sie über Ihre Ergebnisse.
- (d) Diskutieren Sie, inwiefern die Erklärung für eine *nicht-technische* Nutzergruppe brauchbar ist. Was würden Sie an der Darstellung ändern?

5. **Reflexion: Erklärungen im Alltag.** Betrachten Sie ein bekanntes Erklär-UI, z. B. „*Warum diese Anzeige?*“ (Suchmaschine/Facebook), „*Weil Sie X gesehen haben*“ (Streaming), oder *Produkttempfehlungen* im E-Commerce.

- (a) Inwiefern sind diese Erklärungen *nützlich*?
- (b) Welche Informationen fehlen?
- (c) Skizzieren Sie eine verbesserte Erklärung (Wireframe oder drei Bullet Points).

Dieses Übungsblatt ist Teil des WPFs „*Deep Learning, Machine Learning und KI*“.