

Vorabfragen

- Stellen Sie sich vor, Sie möchten ein Machine-Learning-Modell trainieren. Warum könnte es problematisch sein, die Daten nicht in Trainings- und Testdaten aufzuteilen?
- Ein Datensatz enthält Messwerte eines Sensors über mehrere Monate. Welche Probleme könnten entstehen, wenn diese Daten zufällig in Trainings- und Testdaten aufgeteilt werden?
- Sie erhalten einen Datensatz mit vielen fehlenden Werten und Ausreißern. Welche Strategien fallen Ihnen spontan ein, um mit solchen Problemen umzugehen?
- Ein Datensatz enthält ein Merkmal wie „Produktkategorie“ (z. B. A, B, C). Warum könnte es problematisch sein, diese Kategorien direkt als Zahlen (z. B. 1, 2, 3) zu verwenden?



Deep Learning, Machine Learning und Künstliche Intelligenz – SS 26

Gelesen von Prof. Dr. Daniel Gaida

Lernziele von heute und Fragen zur Überprüfung der Lernziele

Die Studierenden können ein Machine Learning Projekt selbstständig durchführen, indem sie

- die Aufgabenstellung als eine Machine Learning Problemstellung formulieren,
 - gegebene Daten visualisieren und für Machine Learning aufbereiten,
 - mehrere Machine Learning Modelle trainieren,
 - deren Hyperparameter anhand des Validierungsdatensatzes optimieren,
 - sich für das beste Machine Learning Modell entscheiden und dieses final testen,
- um später eigene Machine Learning Projekte umsetzen zu können.

Überprüfung des Lernziels: S. fortlaufende Übung in diesem Lernraum I.

Lernraum I: Wie wird ein Machine Learning Projekt durchgeführt?

- Ein Machine Learning Projekt von A bis Z
 - Klären Sie die Aufgabenstellung und betrachten Sie die Gesamtsituation
 - Beschaffen Sie sich Daten
 - Erkunden und visualisieren Sie die Daten, um daraus Erkenntnisse zu gewinnen
 - Bereiten Sie die Daten so auf, dass Machine-Learning-Algorithmen die Muster darin leichter erkennen können
 - Probieren Sie viele unterschiedliche Modelle aus und treffen Sie eine engere Auswahl
 - Optimieren Sie Ihre Modelle und kombinieren Sie diese zu einer guten Lösung
 - Stellen Sie Ihre Lösung vor
 - Starten, beobachten und warten Sie Ihr System

Ein Machine Learning Projekt von A bis Z

Empfehlungen zur Vorgehensweise

- Checkliste für Machine-Learning Projekte aus Geron19 (Anhang B)
- CRISP-DM

Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Checkliste für Machine-Learning-Projekte

Diese Checkliste begleitet Sie durch Ihre Machine-Learning-Projekte. Sie besteht aus acht wesentlichen Punkten:

1. Klären Sie die Aufgabenstellung und betrachten Sie die Gesamtsituation.
2. Beschaffen Sie sich Daten.
3. Erkunden Sie die Daten, um daraus Erkenntnisse zu gewinnen.
4. Bereiten Sie die Daten so auf, dass Machine-Learning-Algorithmen die Muster darin leichter erkennen können.
5. Probieren Sie viele unterschiedliche Modelle aus und treffen Sie eine engere Auswahl.
6. Optimieren Sie Ihre Modelle und kombinieren Sie diese zu einer guten Lösung.
7. Stellen Sie Ihre Lösung vor.
8. Starten, beobachten und warten Sie Ihr System.

Natürlich sollten Sie diese Checkliste bei Bedarf anpassen.


Klären Sie die Aufgabenstellung und betrachten Sie die Gesamtsituation

1. Definieren Sie das Geschäftsziel.
2. Wie wird Ihre Lösung eingesetzt werden?
3. Wie sehen die bisherigen Lösungen oder Übergangslösungen aus (falls vorhanden)?
4. In welchen Bereich fällt die Aufgabe (überwacht/unüberwacht, online/offline und so weiter)?
5. Wie wird die Qualität der Lösung gemessen?
6. Liefert das Qualitätsmaß einen Beitrag zum Geschäftsziel?

Ein Machine Learning Projekt von A bis Z

CRISP-DM

- Cross-Industry Standard Process for Data Mining
- In dieser Vorlesung gehen wir nach dem CRISP-DM Standard vor, ohne diesen groß zu erwähnen



Quelle: W. Konen, WPF Machine Learning,
Deep Learning und KI, WS2019

Der Umgang mit realen Daten

Datenquellen

Beliebte Archive mit frei verfügbaren Daten:

- Datensätze von Kaggle (<https://www.kaggle.com/datasets>)
- UC Irvine Machine Learning Repository (<http://archive.ics.uci.edu/ml/>)
- Datensätze von Amazon AWS (<https://registry.opendata.aws/>)
- Roboflow (<https://universe.roboflow.com/>)

Metaseiten (Listen von Datenarchiven):

- Data Portals (<http://dataportals.org/>)
- OpenDataMonitor (<http://opendatamonitor.eu/>)

Andere Seiten, die beliebte offene Datenarchive auflisten:

- Die Wikipedia-Seite mit Machine-Learning-Datensätzen (<https://homl.info/9>)


Daten Suchmaschine:

- <https://datasetsearch.research.google.com/>

Der Umgang mit realen Daten

Datensatz für unser Projekt:

- Immobilienpreise in Kalifornien
 - Lage
 - Mittleres Einkommen
 - Anzahl Räume
 - Einwohnerzahl (Population)
- Alle Daten liegen für jeden Bezirk als Mittelwerte vor
 - Bezirk: ca.: 600 – 3000 Personen




Lernraum I: Wie wird ein Machine Learning Projekt durchgeführt?

- Ein Machine Learning Projekt von A bis Z
 - **Klären Sie die Aufgabenstellung und betrachten Sie die Gesamtsituation**
 - Beschaffen Sie sich Daten
 - Erkunden und visualisieren Sie die Daten, um daraus Erkenntnisse zu gewinnen
 - Bereiten Sie die Daten so auf, dass Machine-Learning-Algorithmen die Muster darin leichter erkennen können
 - Probieren Sie viele unterschiedliche Modelle aus und treffen Sie eine engere Auswahl
 - Optimieren Sie Ihre Modelle und kombinieren Sie diese zu einer guten Lösung
 - Stellen Sie Ihre Lösung vor
 - Starten, beobachten und warten Sie Ihr System

Klären Sie Aufgabenstellung und betrachten Sie Gesamtsituation

- Aufgabe: Vorhersage des Immobilienpreises je Bezirk auf Basis der erhobenen Merkmale je Bezirk (Lage, mittleres Einkommen, Anzahl Räume, ...)
- Die Aufgabe abstecken
- Wähle ein Qualitätsmaß aus
- Überprüfe die Annahmen



Klären Sie Aufgabenstellung und betrachten Sie Gesamtsituation

Die Aufgabe abstecken

- Das Geschäftsziel verstehen
 - Lohnt sich die Investition in Immobilien in bestimmten Bezirken?
- Wie soll das Machine Learning Modell am Ende genutzt werden?
 - Teil eines größeren Systems?
- Wie wird es ausgerollt und mit welchen anderen Software-Komponenten soll es zusammen arbeiten?
 - Zugriff auf eine bestimmte Datenbank,
 - Integration des Modells in eine inhouse entwickelte Software, ...
 - Mobile Nutzung?
- Wie sieht die aktuelle Lösung aus (falls vorhanden)?
 - Liefert u.A. Hinweise auf aktuelle Vorhersagegenauigkeiten
- Handelt es sich bei der Aufgabe um überwachtes, unüberwachtes oder Reinforcement Learning?
- Ist es eine Klassifikationsaufgabe, eine Regressionsaufgabe oder etwas anderes?

Klären Sie Aufgabenstellung und betrachten Sie Gesamtsituation

Notation in dieser Vorlesung

- Unser Datensatz hat m Datenpunkte: $i = 1, \dots, m$
- Jeder Datenpunkt besteht aus mehreren Merkmalen

							Merkmal				
	median_house_value	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	ocean_proximity	
	452600.0	-122.23	37.88	41.0	880.0	129.0	322.0	126.0	8.3252	NEAR BAY	
Label	358500.0	-122.22	37.86	21.0	7099.0	1106.0	2401.0	1138.0	8.3014	NEAR BAY	
	352100.0	-122.24	37.85	52.0	1467.0	190.0	496.0	177.0	7.2574	NEAR BAY	
Datenpunkt	341300.0	-122.25	37.85	52.0	1274.0	235.0	558.0	219.0	5.6431	NEAR BAY	
	342200.0	-122.25	37.85	52.0	1627.0	280.0	565.0	259.0	3.8462	NEAR BAY	

Klären Sie Aufgabenstellung und betrachten Sie Gesamtsituation

Notation in dieser Vorlesung

- Unser Datensatz hat m Datenpunkte: $i = 1, \dots, m$

$$X := \begin{pmatrix} (\mathbf{x}_1)^T \\ (\mathbf{x}_2)^T \\ \vdots \\ (\mathbf{x}_{m-1})^T \\ (\mathbf{x}_m)^T \end{pmatrix}$$

y		$\begin{pmatrix} (\mathbf{x}_{m-1})^T \\ (\mathbf{x}_m)^T \end{pmatrix}$								
median_house_value	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	ocean_proximity	
452600.0	-122.23	37.88	41.0	880.0	129.0	322.0	126.0	8.3252	NEAR BAY	
358500.0	-122.22	37.86	21.0	7099.0	1106.0	2401.0	1138.0	8.3014	NEAR BAY	
352100.0	-122.24	37.85	52.0	1467.0	190.0	496.0	177.0	7.2574	NEAR BAY	
341300.0	-122.25	37.85	52.0	1274.0	235.0	558.0	219.0	5.6431	NEAR BAY	
y_i — 342200.0	-122.25	37.85	$\mathbf{x}_i$	52.0	1627.0	280.0	565.0	259.0	3.8462	NEAR BAY

Klären Sie Aufgabenstellung und betrachten Sie Gesamtsituation

Notation in dieser Vorlesung

m ist die Anzahl der Datenpunkte im Datensatz

$\mathbf{x}_i$ ist ein Vektor der Werte aller Merkmale (ohne das Label) des i ten Datenpunkts im Datensatz, und y_i ist das dazugehörige Label (der gewünschte Ausgabewert für diesen Datenpunkt).

$\mathbf{X}$ ist eine Matrix mit den Werten sämtlicher Merkmale (ohne Labels) für alle Datenpunkte im Datensatz. Pro Datenpunkt gibt es eine Zeile, und die i te Zeile entspricht der transponierten Form von $\mathbf{x}_i$, auch als $(\mathbf{x}_i)^T$ geschrieben.

$$\mathbf{X} := \begin{pmatrix} (\mathbf{x}_1)^T \\ (\mathbf{x}_2)^T \\ \vdots \\ (\mathbf{x}_{m-1})^T \\ (\mathbf{x}_m)^T \end{pmatrix}$$

Formel 1-1: Ein einfaches lineares Modell

Zufriedenheit = $\theta_0 + \theta_1 \times \text{BIP_pro_Kopf}$

h ist die Vorhersagefunktion des Systems, auch Hypothese genannt. Wenn das System den Merkmalsvektor eines Datenpunkts $\mathbf{x}_i$ erhält, gibt es den Vorhersagewert $\hat{y}_i = h(\mathbf{x}_i)$ für diesen Datenpunkt aus.

Klären Sie Aufgabenstellung und betrachten Sie Gesamtsituation


Wähle ein Qualitätsmaß aus

- Wie soll die Qualität der Modellvorhersagen (Vorhersagefehler) gemessen werden?
- Stimmen diese mit dem Geschäftsziel überein?
- RMSE (root-mean-square error, Wurzel der mittleren quadratischen Abweichung)

$$\text{RMSE}(\mathbf{X}, h) := \sqrt{\frac{1}{m} \sum_{i=1}^m (h(\mathbf{x}_i) - y_i)^2}$$

- MAE (mittlerer absoluter Fehler)

$$\text{MAE}(\mathbf{X}, h) := \frac{1}{m} \sum_{i=1}^m |h(\mathbf{x}_i) - y_i|$$



Klären Sie Aufgabenstellung und betrachten Sie Gesamtsituation

Überprüfe die Annahmen

- Wie werden die Vorhersagen des ML Modells von nachgeschalteter Software genutzt?
 - Werden Preise genutzt oder nur Kategorien wie günstig, mittel und teuer?
 - Falls ja, dann ...
 - Problem als Klassifikationsproblem formulieren
- Stimmen Sie Ihre getroffenen Annahmen mit dem Auftraggeber ab.
- Was müssten wir bis hierhin ändern, wenn das Problem ein Klassifikationsproblem wäre?
 - Die Aufgabe abstecken?
 - Notation?
 - Wähle ein Qualitätsmaß aus?

Klären Sie Aufgabenstellung und betrachten Sie Gesamtsituation

Wähle ein Qualitätsmaß aus


Leitfrage:

- Wie bewertet man die Qualität eines Klassifikationsmodells?

Klären Sie Aufgabenstellung und betrachten Sie Gesamtsituation

Wähle ein Qualitätsmaß aus – Binärer Klassifikator für Katzen

Klassifizieren Sie alle Katzen



12.05.2026

Prof. Dr. Daniel Gaida

Professor für Cyber-Physische

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Seite 23

Making Friends with Machine Learning: The Entire Course, 1:57:30,
https://www.youtube.com/watch?v=1vkb7BCMqD0&list=PLRKtJ4lpxJpDsQT_8YDREJrO8cQUtPUVq&t=8s

Klären Sie Aufgabenstellung und betrachten Sie Gesamtsituation

Wähle ein Qualitätsmaß aus – Konfusionsmatrix

Perfekter Klassifikator:



		ML system says	
		Cat	No Cat
Truth	Cat	4 	0
	No Cat	0	2 

Klären Sie Aufgabenstellung und betrachten Sie Gesamtsituation

Wähle ein Qualitätsmaß aus – Konfusionsmatrix



		ML system says	
		Cat	No Cat
Truth	Cat	Richtig	Falsch
	No Cat	Falsch	Richtig

Klären Sie Aufgabenstellung und betrachten Sie Gesamtsituation

Wähle ein Qualitätsmaß aus – Konfusionsmatrix



		ML system says	
		Cat	No Cat
Truth	Cat	Positive	Negative
	No Cat	Positive	Negative

Klären Sie Aufgabenstellung und betrachten Sie Gesamtsituation

Wähle ein Qualitätsmaß aus – Konfusionsmatrix




		ML system says	
		Cat	No Cat
Truth	Cat	Richtig Positive	Falsch Negative
	No Cat	Falsch Positive	Richtig Negative

Klären Sie Aufgabenstellung und betrachten Sie Gesamtsituation

Wähle ein Qualitätsmaß aus – Konfusionsmatrix

Genauigkeit = $4/6 = 66\%$



		ML system says	
		Cat	No Cat
Truth	Cat	3 	1 
	No Cat	1 	1 

Klären Sie Aufgabenstellung und betrachten Sie Gesamtsituation

Wähle ein Qualitätsmaß aus

RP	FN
FP	RN

- Binäres Klassifikationsproblem:
 - Genauigkeit = $(RP + RN) / (RP + RN + FP + FN)$
- Multinomiales Klassifikationsproblem (mehrere Klassen):
 - Konfusionsmatrix
 - Genauigkeit pro Klasse =
Anzahl richtig klassifiziert / Anzahl Datenpunkte in Klasse
 - Genauigkeit für Datensatz =
Anzahl richtig klassifiziert / Anzahl Datenpunkte in Datensatz

0 0
1 1
2 2
3 3
4 4
5 5
6 6
7 7
8 8
9 9

True digit \ Predicted digit	0	1	2	3	4	5	6	7	8	9
0	978	0	0	0	0	0	0	1	1	0
1	0	1135	0	0	0	0	0	0	0	0
2	0	1	1030	0	0	0	0	1	0	0
3	0	0	0	1009	0	1	0	0	0	0
4	0	0	0	0	980	0	1	0	0	1
5	0	0	0	3	0	888	1	0	0	0
6	1	1	0	0	0	1	955	0	0	0
7	0	2	0	0	0	0	0	1025	0	1
8	0	0	1	1	0	0	0	0	971	1
9	0	0	0	0	4	0	0	1	0	1004

Fragen?

- Klären Sie die Aufgabenstellung und betrachten Sie die Gesamtsituation
 - Annahmen klären
 - Metrik wählen

Lernraum I: Wie wird ein Machine Learning Projekt durchgeführt?

- Ein Machine Learning Projekt von A bis Z
 - Klären Sie die Aufgabenstellung und betrachten Sie die Gesamtsituation
 - **Beschaffen Sie sich Daten**
 - Erkunden und visualisieren Sie die Daten, um daraus Erkenntnisse zu gewinnen
 - Bereiten Sie die Daten so auf, dass Machine-Learning-Algorithmen die Muster darin leichter erkennen können
 - Probieren Sie viele unterschiedliche Modelle aus und treffen Sie eine engere Auswahl
 - Optimieren Sie Ihre Modelle und kombinieren Sie diese zu einer guten Lösung
 - Stellen Sie Ihre Lösung vor
 - Starten, beobachten und warten Sie Ihr System


Beschaffen Sie sich Daten

- Erstelle eine Arbeitsumgebung
- Die Daten herunterladen
- Einen kurzen Blick auf die Datenstruktur werfen
- Erstelle einen Testdatensatz

Beschaffen Sie sich Daten

Erstelle eine Arbeitsumgebung

- Lokale Installation:
 - Anaconda (oder Miniconda),
<https://www.anaconda.com/products/individual>
 - Enthält Python und viele Standard Bibliotheken
 - Jupyter Notebook oder Jupyter Lab
 - Pandas, Scikit-learn, Matplotlib
 - Später: TensorFlow
- Cloud Umgebung:
 - Google Colab



Beschaffen Sie sich Daten

Erstelle eine Arbeitsumgebung

- Mit diesen Bibliotheken arbeiten wir in diesem Kurs:
 - Jupyter Notebook oder Jupyter Lab
 - Praktisch, um schnell und im Browser Python zu programmieren
 - Pandas
 - Der Standard, um strukturierte Daten (bspw. Tabellen) in Python zu verarbeiten
 - Matplotlib, Seaborn
 - Visualisierung in Python
 - Scikit-learn
 - Die Standardbibliothek für Machine Learning in Python
 - Später: TensorFlow
 - Neben PyTorch der Standard, um tiefe neuronale Netze zu trainieren

Beschaffen Sie sich Daten

Erstelle eine Arbeitsumgebung

- Es empfiehlt sich mit einer standardisierten und logischen Ordner- und Dateistruktur zu arbeiten
 - Übersichtlichkeit – Alle die die Struktur kennen, wissen wo sie etwas finden
 - Reproduzierbarkeit – Auch noch nach ein paar Jahren
 - Wiederverwendbarkeit – Klassen und Methoden können in neuen Projekten genutzt werden
- Cookiecutter kann solch eine Ordnerstruktur erstellen
 - <https://cookiecutter.readthedocs.io/en/1.7.2/>
- Gutes Template für Machine Learning Projekte:
 - <http://drivendata.github.io/cookiecutter-data-science/>
- Eine Empfehlung für zukünftige Projekte (Praxisprojekt, Bachelorarbeit, ...)

```
src          <- Source code for use in this project.
├── __init__.py  <- Makes src a Python module
├── data          <- Scripts to download or generate data
│   └── make_dataset.py
├── features      <- Scripts to turn raw data into features for modeling
│   └── build_features.py
├── models        <- Scripts to train models and then use trained models to make
│                   predictions
│   ├── predict_model.py
│   └── train_model.py
└── visualization <- Scripts to create exploratory and results oriented visualizations
    └── visualize.py
```

Beschaffen Sie sich Daten

Erstelle eine Arbeitsumgebung

- Cookiecutter Template für ML Projekte:
 - <http://drivendata.github.io/cookiecutter-data-science/>

└─ LICENSE	<- Makefile with commands like `make data` or `make train`
└─ Makefile	<- The top-level README for developers using this project.
└─ README.md	
└─ data	
└─ external	<- Data from third party sources.
└─ interim	<- Intermediate data that has been transformed.
└─ processed	<- The final, canonical data sets for modeling.
└─ raw	<- The original, immutable data dump.
└─ docs	<- A default Sphinx project; see sphinx-doc.org for details
└─ models	<- Trained and serialized models, model predictions, or model summaries
└─ notebooks	<- Jupyter notebooks. Naming convention is a number (for ordering), the creator's initials, and a short `-' delimited description, e.g. `1.0-jqp-initial-data-exploration`.
└─ references	<- Data dictionaries, manuals, and all other explanatory materials.
└─ reports	<- Generated analysis as HTML, PDF, LaTeX, etc.
└─ figures	<- Generated graphics and figures to be used in reporting
└─ requirements.txt	<- The requirements file for reproducing the analysis environment, e.g. generated with `pip freeze > requirements.txt`
└─ setup.py	<- Make this project pip installable with `pip install -e`
└─ src	<- Source code for use in this project.
└─ __init__.py	<- Makes src a Python module
└─ data	<- Scripts to download or generate data
└─ make_dataset.py	
└─ features	<- Scripts to turn raw data into features for modeling
└─ build_features.py	
└─ models	<- Scripts to train models and then use trained models to make predictions
└─ predict_model.py	
└─ train_model.py	
└─ visualization	<- Scripts to create exploratory and results oriented visualizations
└─ visualize.py	
└─ tox.ini	<- tox file with settings for running tox; see tox.readthedocs.io

Beschaffen Sie sich Daten

Die Daten herunterladen

- Am Besten alle Schritte automatisieren, um diese auf neue Daten anwenden zu können
- Funktion schreiben, zum Herunterladen der Daten
 - `urllib.request.urlretrieve()`
- Daten in pandas einlesen
- Was ist pandas (Python and Data Analysis)?
 - Pandas ist ein leistungsstarkes Python Datenanalyse Toolkit, das auf NumPy aufbaut und als Bibliothek in Python verfügbar ist
 - Im Mittelpunkt von Pandas stehen DataFrame-Objekte. Als Excel-Tabelle vorstellbar.

Beschaffen Sie sich Daten

Die Daten in Python importieren

Im Folgenden: **Python's Datenanalyse Toolkit Pandas** (Python and Data Analysis)

```
1 import pandas as pd
2
3 df_csv = pd.read_csv("../DeinPfad/Datei.csv")
4 df_excel = pd.read_excel("../DeinPfad/Datei.xlsx")
```

```
1 import pandas as np
2 from pymongo import MongoClient
3
4 connect_string='mongodb://USER://:PW@DBHOST/DB'
5 conn = MongoClient(connect_string)
6 db = conn['DB'] # äquivalent zu conn.DB
7 collection = db['test_collection'] # äquivalent zu db.test_collection
8 df.nosql = pd.DataFrame(list(collection.find()))
```

```
1 import pandas as pd
2 import sqlalchemy as sql
3
4 connect_string = 'mysql://USER:PW@DBHOST/DB'
5 sql_engine = sql.create_engine(connect_string)
6
7 df_sql_query = pd.read_sql_query(query, sql_engine)
8 dt_sql_table = pd.read_sql_table("name", con=sql_engine)
```

Beschaffen Sie sich Daten

Übung – Die Daten in Python importieren

- Laden Sie die Daten herunter und lesen Sie die Daten mit pandas in Python ein.
- Gehen Sie zu: https://dgaida.github.io/wpf_dlml_th_public/vorlesungen-uebungen/

Woche 3 - Machine Learning Projekt von A-Z Part 1

06.05.:	VORLESUNG	Machine Learning Projekt von A-Z Part 1	Raum 0.503, 9:15-11:00
06.05.:	ÜBUNG	Machine Learning Projekt von A-Z Part 1	Raum 0.503, 11:00-12:00

Materialien:

- end
- to end
- machine learning project student
- Machine Learning Projekt A2Z animated

■ 10 Min.

1.1. Download the Data



```
from pathlib import Path
import pandas as pd
import tarfile
import urllib.request
import numpy as np

def load_housing_data():
    tarball_path = Path("datasets/housing.tgz")
    if not tarball_path.is_file():
        Path("datasets").mkdir(parents=True, exist_ok=True)
        url = "https://github.com/ageron/data/raw/main/housing.tgz"
        urllib.request.urlretrieve(url, tarball_path)
        with tarfile.open(tarball_path) as housing_tarball:
            housing_tarball.extractall(path="datasets")
    return pd.read_csv(Path("datasets/housing/housing.csv"))

housing = load_housing_data()
```

Beschaffen Sie sich Daten


Übung – Google Colab – Erste Schritte



Beschaffen Sie sich Daten

Einen kurzen Blick auf die Datenstruktur werfen

- Nützliche Methoden eines DataFrame Objekts
 - `head()` → Gibt die ersten n Zeilen des DataFrames aus
 - `info()` → Gibt Anzahl Zeilen, Datentyp des Attributs und Anzahl Werte ungleich null aus
 - `value_counts()` → Gibt Anzahl unterschiedlicher Kategorien eines kategorischen Merkmals aus
 - `describe()` → Gibt numerische Zusammenfassung über alle numerischen Merkmale (mean, std, min, max, ...) aus
- Histogramme (`hist()`)
 - Stellt die Häufigkeiten eines Merkmals grafisch dar
 - Gibt Aufschluss über die tatsächliche Verteilung (gleichverteilt, gaußverteilt, ...)



Beschaffen Sie sich Daten

Übung - Einen kurzen Blick auf die Datenstruktur werfen

- Machen Sie sich mit dem Datensatz vertraut unter Nutzung der Methoden:

- `head()`
- `info()`
- `value_counts()`
- `describe()`
- `hist()`

```
In [5]: housing = load_housing_data()
housing.head()
```

```
Out[5]:
```

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value	ocean_proximity
0	-122.23	37.88	41.0	880.0	129.0	322.0	126.0	8.3252	452600.0	NEAR BAY
1	-122.22	37.86	21.0	7099.0	1106.0	2401.0	1138.0	8.3014	358500.0	NEAR BAY
2	-122.24	37.85	52.0	1467.0	190.0	496.0	177.0	7.2574	352100.0	NEAR BAY
3	-122.25	37.85	52.0	1274.0	235.0	558.0	219.0	5.6431	341300.0	NEAR BAY
4	-122.25	37.85	52.0	1627.0	280.0	565.0	259.0	3.8462	342200.0	NEAR BAY


```
In [6]: housing.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20640 entries, 0 to 20639
Data columns (total 10 columns):
#   Column                Non-Null Count  Dtype
---  -
0   longitude             20640 non-null  float64
1   latitude              20640 non-null  float64
2   housing_median_age    20640 non-null  float64
3   total_rooms           20640 non-null  float64
4   total_bedrooms        20433 non-null  float64
5   population            20640 non-null  float64
6   households            20640 non-null  float64
7   median_income         20640 non-null  float64
8   median_house_value    20640 non-null  float64
9   ocean_proximity       20640 non-null  object
dtypes: float64(9), object(1)
memory usage: 1.6+ MB
```

Beschaffen Sie sich Daten

Einen kurzen Blick auf die Datenstruktur werfen

- Was ist Ihnen bei den Histogrammen aufgefallen?



Beschaffen Sie sich Daten

Erstelle einen Testdatensatz

Wichtig!

- Bevor Sie sich den Datensatz im Detail anschauen, trennen Sie diesen in zwei disjunkte Teile:
 - Trainingsdatensatz (ca. 70 % der Daten) trainiert das Machine Learning Modell
 - Testdatensatz (ca. 30 % der Daten) testet das Machine Learning Modell
- Bei sehr großen Datensätzen (> 1 Mio. gelabelte Daten), darf der Testdatensatz auch kleiner ausfallen (5 %)

Wichtig!

- Testdatensatz nicht weiter anschauen, sondern wegschließen und vergessen... ;-)
- Test auf Testdaten darf nur **einmal** erfolgen, da man sonst auf dem Testdatensatz optimiert

Beschaffen Sie sich Daten

Erstelle einen Testdatensatz

Merke:

- Testdatensatz muss den erwarteten Datensatz möglichst gut repräsentieren
- Wenn Machine Learning Modelle in der Praxis nicht den erwünschten Erfolg liefern, liegt dieses meistens an der **falschen Wahl des Testdatensatzes!**

Einfache Fehler:

- Testdatensatz einer Bohrmaschine enthält nur Daten mit niedrigen Drehzahlen, Trainingsdatensatz nur mit hohen Drehzahlen
- Trainingsdatensatz für ein Hotel enthält nur Daten aus dem Sommer
- Das funktioniert schon beim Testen des Machine Learning Modells nicht

ABER ACHTUNG: ES GIBT AUCH WEITERE FEHLERQUELLEN!


Beschaffen Sie sich Daten

Erstelle einen Testdatensatz - Beispiel

- Ein Maschinenhersteller möchte für seine Kunden den Ausfall seiner Maschinen vorhersagen (vorausschauende Wartung)
 - Hersteller hat Daten von 8 seiner Kunden, welche je 4-5 seiner (baugleichen) Maschinen betreiben
 - Seine Kunden möchten mit einem ML-Modell für alle deren Maschinen (und zukünftige Maschinen) zukünftige Ausfälle vorhersagen.
 - Wie könnten Sie die Daten in Trainings- und Testdaten aufteilen?
-
- Bitte gehen Sie zu www.menti.com und nutzen den Code 43 75 16

Beschaffen Sie sich Daten

Erstelle einen Testdatensatz - Beispiel



- Seine Kunden möchten mit einem ML-Modell für alle deren Maschinen (und zukünftige Maschinen) zukünftige Ausfälle vorhersagen. Wie könnten Sie die Daten in Trainings- und Testdaten aufteilen?

Auf keinen Fall

Testdaten: Von einem Kunden randomisiert ausgewählte Maschinendaten (ca. 30%). Trainingsdaten: Verbliebene Maschinendaten des gleichen Kunden

Als Testdaten nehmen Sie von einem Kunden die Daten von 2 Maschinen und als Trainingsdaten die Daten der verbliebenen 3 Maschinen des gleichen Kunden

Als Testdaten nehmen Sie von jedem Kunden die Daten von 1-2 Maschinen und als Trainingsdaten die Daten der verbliebenen 2-3 Maschinen jedes Kunden


Testdaten: Von jedem Kunden nehmen Sie die neuesten 30% aller Maschinendaten. Trainingsdaten: Verbliebene Maschinendaten aller Kunden

Ja, auf jeden Fall

Beschaffen Sie sich Daten

Erstelle einen Testdatensatz - Beispiel

- Seine Kunden möchten mit einem ML-Modell für zukünftige Ausfälle vorhersagen. Wie könnten Sie



Auf keinen Fall

Testdaten: Von einem Kunden randomisiert ausgewählte Maschinendaten (ca. 30%). Trainingsdaten: Verbliebene Maschinendaten des gleichen Kunden

Als Testdaten nehmen Sie von einem Kunden die Daten von 2 Maschinen und als Trainingsdaten die Daten der verbliebenen 3 Maschinen des gleichen Kunden

Als Testdaten nehmen Sie von jedem Kunden die Daten von 1-2 Maschinen und als Trainingsdaten die Daten der verbliebenen 2-3 Maschinen jedes Kunden

Testdaten: Von jedem Kunden nehmen Sie die neuesten 30% aller Maschinendaten. Trainingsdaten: Verbliebene Maschinendaten aller Kunden

Ja, auf jeden Fall

Beschaffen Sie sich Daten

Erstelle einen Testdatensatz - Beispiel



- Seine Kunden möchten mit einem ML-Modell für alle deren Maschinen (und zukünftige Maschinen) zukünftige Ausfälle vorhersagen. Wie könnten Sie die Daten in Trainings- und Testdaten aufteilen?

Auf keinen Fall

Testdaten: Von einem Kunden randomisiert ausgewählte Maschinendaten (ca. 30%). Trainingsdaten: Verbliebene Maschinendaten des gleichen Kunden

Als Testdaten nehmen Sie von einem Kunden die Daten von 2 Maschinen und als Trainingsdaten die Daten der verbliebenen 3 Maschinen des gleichen Kunden

Als Testdaten nehmen Sie von jedem Kunden die Daten von 1-2 Maschinen und als Trainingsdaten die Daten der verbliebenen 2-3 Maschinen jedes Kunden

Testdaten: Von jedem Kunden nehmen Sie die neuesten 30% aller Maschinendaten. Trainingsdaten: Verbliebene Maschinendaten aller Kunden

Ja, auf jeden Fall


Beschaffen Sie sich Daten

Erstelle einen Testdatensatz - Beispiel


Beste Option:

- Trainingsdaten: von 2-3 Maschinen jedes Kunden die ältesten 70 % der Daten nehmen
- Testdaten: 1-2 Maschinen, die nicht für Training genutzt wurden, die neuesten 30 % der Daten nehmen

■ Maschine 1:



■ Maschine 2:



Beschaffen Sie sich Daten

Erstelle einen Testdatensatz

Warum sollten bei Zeitreihen die Testdaten neuer sein als die Trainingsdaten?

- Trainiertes Modell soll im Einsatz funktionieren, d.h. für zukünftige Daten.
- Deshalb sollten die Testdaten sicherheitshalber neuer als die Trainingsdaten sein, um während des Tests zu simulieren, dass das Modell gute Vorhersagen für Daten machen kann, die neuer als die Trainingsdaten sind

Beschaffen Sie sich Daten

Erstelle einen Testdatensatz

- Wenn Ihre Daten
 - keine Zeitabhängigkeit und
 - keine Objektzugehörigkeit (Maschine, Patient, Sprecher, Kamera, Tier) haben und diese Information wichtig ist (ML-Modell soll auch für unbekannte Maschine, Patient, ... gute Ergebnisse liefern),
 - Oder sich die Grundgesamtheit nicht verändert (Bspw. kommen zu Kalifornien keine weiteren Bezirke hinzu, d.h. Trainings-/Testdatensatz decken gesamten Wertebereich ab)
- können Sie diese auch zufällig in Trainings- und Testdaten einteilen

- `train_test_split`
 - Teilt Datensatz zufällig in Trainings- und Testdatensatz auf

```
from sklearn.model_selection import train_test_split
```

```
train_set, test_set = train_test_split(housing, test_size=0.2, random_state=42)
```

- S. Jupyter Notebook

Beschaffen Sie sich Daten

Erstelle einen Testdatensatz

Warum können wir bei unserem Datensatz die Daten zufällig in Training- und Testdaten aufteilen?


- Wir wollen das Modell nur in Kalifornien nutzen und nicht in anderen Staaten
 - Falls doch, dann müssen im Testdatensatz Daten von mind. einem anderen Staat existieren, wobei der Staat nicht im Trainingsdatensatz enthalten ist
- Wir wollen nicht prüfen ob mit nur den Daten aus San Francisco Vorhersagen für ganz Kalifornien gemacht werden können.
 - Falls doch, dann
 - Trainingsdatensatz: San Francisco
 - Testdatensatz: alle anderen Daten
 - Oder Testdatensatz: Daten aus Los Angeles, wenn wir prüfen möchten, ob mit Daten aus SF Vorhersagen für LA (bzw. andere Großstädte) gemacht werden können

Lernraum I: Wie wird ein Machine Learning Projekt durchgeführt?

- Ein Machine Learning Projekt von A bis Z
 - Klären Sie die Aufgabenstellung und betrachten Sie die Gesamtsituation
 - Beschaffen Sie sich Daten
 - **Erkunden und visualisieren Sie die Daten, um daraus Erkenntnisse zu gewinnen**
 - Bereiten Sie die Daten so auf, dass Machine-Learning-Algorithmen die Muster darin leichter erkennen können
 - Probieren Sie viele unterschiedliche Modelle aus und treffen Sie eine engere Auswahl
 - Optimieren Sie Ihre Modelle und kombinieren Sie diese zu einer guten Lösung
 - Stellen Sie Ihre Lösung vor
 - Starten, beobachten und warten Sie Ihr System

Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen

- Visualisieren
- Suche nach Korrelationen
- Experimentieren mit Kombinationen von Merkmalen




Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen

Visualisieren

Die Datenvisualisierung:

- verschafft einen Überblick
- dient zur Datenanalyse
- hilft bei der Dokumentation
- sowie der Kommunikation




Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen

Suche nach Korrelationen

- Berechnung des Korrelationskoeffizienten zwischen allen Merkmalen, insbesondere zur Zielgröße
 - Der Pearson-Korrelationskoeffizient liegt zwischen -1 und 1.
 - Der Korrelationskoeffizient erfasst ausschließlich lineare Korrelationen

$$r_{x,z} := \frac{\sum_{i=1}^m (x_i - \bar{x})(z_i - \bar{z})}{\sqrt{\sum_{i=1}^m (x_i - \bar{x})^2 \sum_{i=1}^m (z_i - \bar{z})^2}}$$

x_i und z_i sind einzelne Werte der Merkmale $\mathbf{x}$ und $\mathbf{z}$. $\bar{x}$ und $\bar{z}$ sind die Mittelwerte der beiden Merkmale.



Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen

Suche nach Korrelationen


Pandas Methode: `corr()`

```
corr_matrix = housing.corr()
```

Seaborn:

- <https://seaborn.pydata.org/>
- Basiert auf matplotlib

```
seaborn.heatmap(corr_matrix)
```




Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen

Suche nach Korrelationen

- **Streudiagramme** vergleichen zwei Merkmale miteinander
- Zusätzliche **Randdiagramme** veranschaulichen Beziehungen zwischen den zwei Merkmalen

Bild


- Bildmitte zeigt ein Streudiagramm
 - Randdiagramme zeigen Projektionen der zwei Merkmale in Form von Histogrammen
-
- `seaborn.jointplot()`



Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen

Suche nach Korrelationen

`seaborn.pairplot()`



Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen

Übung - Suche nach Korrelationen

```
In [25]: ▶ corr_matrix = housing.corr()
```

```
In [26]: ▶ corr_matrix["median_house_value"].sort_values(ascending=False)
```

```
Out[26]: median_house_value    1.000000
         median_income        0.687160
         total_rooms          0.135097
         housing_median_age    0.114110
         households           0.064506
         total_bedrooms        0.047689
         population           -0.026920
         longitude            -0.047432
         latitude             -0.142724
         Name: median_house_value, dtype: float64
```

```
attributes = ["median_house_value", "median_income", "total_rooms",
              "housing_median_age"]
g = sns.pairplot(housing[attributes], diag_kind="kde")
g.map_lower(sns.kdeplot, levels=4, color=".2")
save_fig("scatter_matrix_plot")
```

Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen

Experimentieren mit Kombinationen von Merkmalen

- Feature Engineering (Teil 1)

```
housing["rooms_per_house"] = housing["total_rooms"] / housing["households"]  
housing["bedrooms_ratio"] = housing["total_bedrooms"] / housing["total_rooms"]  
housing["people_per_house"] = housing["population"] / housing["households"]
```


- Jupyter Notebook

Lernraum I: Wie wird ein Machine Learning Projekt durchgeführt?

- Ein Machine Learning Projekt von A bis Z
 - Klären Sie die Aufgabenstellung und betrachten Sie die Gesamtsituation
 - Beschaffen Sie sich Daten
 - Erkunden und visualisieren Sie die Daten, um daraus Erkenntnisse zu gewinnen
 - **Bereiten Sie die Daten so auf, dass Machine-Learning-Algorithmen die Muster darin leichter erkennen können**
 - Probieren Sie viele unterschiedliche Modelle aus und treffen Sie eine engere Auswahl
 - Optimieren Sie Ihre Modelle und kombinieren Sie diese zu einer guten Lösung
 - Stellen Sie Ihre Lösung vor
 - Starten, beobachten und warten Sie Ihr System

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

- Aufbereiten der Daten
- Bearbeiten von Text und kategorischen Merkmalen
- Skalieren von Merkmalen
- Pipelines zur Transformation



Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Aufbereiten der Daten

- Trennung der Zielvariable (den Labels) von den Merkmalen

```
housing = train_set.drop("median_house_value", axis=1) # drop labels for training set  
housing_labels = train_set["median_house_value"].copy()
```

- Grund: Damit keine Informationen des Labels für die Datenvorverarbeitung genutzt wird

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor


Aufbereiten der Daten

Rohdaten können **fehlerbehaftet** sein und müssen vor einer Analyse aufbereitet werden!

Dies wird als **Data Cleaning** bezeichnet

Wichtig!

- Rohdaten roh halten!
- Datenaufbereitung muss **reproduzierbar** sein




pinterest.es

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Aufbereiten der Daten

Zu den möglichen Fehlern zählen:

- **Ausreißer:** systematisch oder zufällig, z.B. Messfehler, falsche manuelle Eingabe, Sensordefekt
- **Rauschen:** systematisch, z.B. Übertragungsfehler (weißes Rauschen, thermisches Rauschen,...)





Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Aufbereiten der Daten

Zu den möglichen Fehlern zählen:

- **Ausreißer:** systematisch oder zufällig, z.B. Messfehler, falsche manuelle Eingabe, Sensordefekt
- **Rauschen:** systematisch, z.B. Übertragungsfehler (weißes Rauschen, thermisches Rauschen,...)
- **Drift, Saisonalität und Bias:** Sensoren, Kultureller Bias



Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Aufbereiten der Daten

Zu den möglichen Fehlern zählen:

- **Ausreißer:** systematisch oder zufällig, z.B.
Messfehler, falsche manuelle Eingabe, Sensordefekt
- **Rauschen:** systematisch, z.B. Übertragungsfehler
(weißes Rauschen, thermisches Rauschen,...)
- **Drift, Saisonalität und Bias:** Sensoren,
Kultureller Bias (Geschlecht, Rasse, Hautfarbe, Religion)

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Aufbereiten der Daten

Zu den möglichen Fehlern zählen:

- **Ausreißer:** systematisch oder zufällig, z.B. Messfehler, falsche manuelle Eingabe, Sensordefekt
- **Rauschen:** systematisch, z.B. Übertragungsfehler (weißes Rauschen, thermisches Rauschen,...)
- **Drift, Saisonalität und Bias:** Sensoren, Kultureller Bias
- **Fehlende Daten:** meist zufällig, vergessene manuelle Eingabe, Datenverlust über Kommunikationskanal
- **Ungültige Datensätze:** z.B. falscher Datentyp, außerhalb des gültigen Wertebereichs, unvollständig
- **Redundante Informationen:** doppelte oder hochkorrelierte Daten

→ Data Cleaning

- Identifizierung und Behandlung von fehlerhaften Daten

	Date	Humidity	Pressure
	2013-01-01 00:00:00	NaN	1024.0
	2013-01-01 01:00:00	64.0	1022.0
	2013-01-01 02:00:00	69.0	1022.0
	2013-01-01 03:00:00	NaN	1021.0
	2013-01-01 04:00:00	68.0	1021.0
	2013-01-01 05:00:00	68.0	1020.0
	2013-01-01 06:00:00	NaN	NaN
	2013-01-01 07:00:00	68.0	1018.0
	2013-01-01 08:00:00	NaN	1018.0
	2013-01-01 09:00:00	NaN	1018.0
	2013-01-01 10:00:00	69.0	1017.0
	2013-01-01 11:00:00	64.0	1017.0
	2013-01-01 12:00:00	55.0	1017.0
	2013-01-01 13:00:00	59.0	1017.0
	2013-01-01 14:00:00	59.0	1017.0

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor


Aufbereiten der Daten

Fehler	Identifizierung	Behebung
Ausreißer	Sigma-Regel (Z-Score), Boxplot, Max-Min-Intervall	Ersetzen, Feature / Datensatz ignorieren
Fehlende Daten	Pandas isnull(), isnull().values.any(), info()	Ersetzen fillna(), Feature / Datensatz ignorieren dropna()
Ungültige Daten	Boxplot, Pandas where()	Pandas where(), ersetzen von Hand
Rauschen	Scatterplot, Signal-to-Noise-Verhältnis	Pandas rolling_median() Messung wiederholen

Beachte: Entfernen falscher Ausreißer, sogenannte **Exoten**, heißt **Verlust** von **wichtigen Informationen!**


Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Exot oder Ausreißer?



Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Exot oder Ausreißer?



Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Aufbereiten der Daten

- Fehlerhaften Wert des Datenpunkts durch NaN (Not a Number) ersetzen
- Daten Imputation in pandas
 - Dropna() → Entfernt die Zeilen in denen Werte fehlen (damit auch die Werte anderer Merkmale (NA → NaN, None))
 - Drop() → Entfernt das Merkmal vollständig
 - Fillna() → Ersetzt die fehlenden Werte durch einen Standardwert (0, Median, ...)
- SimpleImputer
 - Klasse in scikit-learn für Daten Imputation (Alternative zu fillna())
- SimpleImputer ist nur für numerische Merkmale anwendbar, d.h. kategoriale Merkmale müssen separat verarbeitet werden

Date	Humidity	Pressure
2013-01-01 00:00:00	NaN	1024.0
2013-01-01 01:00:00	64.0	1022.0
2013-01-01 02:00:00	69.0	1022.0
2013-01-01 03:00:00	NaN	1021.0
2013-01-01 04:00:00	68.0	1021.0
2013-01-01 05:00:00	68.0	1020.0
2013-01-01 06:00:00	NaN	NaN
2013-01-01 07:00:00	68.0	1018.0
2013-01-01 08:00:00	NaN	1018.0
2013-01-01 09:00:00	NaN	1018.0
2013-01-01 10:00:00	69.0	1017.0
2013-01-01 11:00:00	64.0	1017.0
2013-01-01 12:00:00	55.0	1017.0
2013-01-01 13:00:00	59.0	1017.0
2013-01-01 14:00:00	59.0	1017.0

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Übung - Aufbereiten der Daten

- Schauen Sie sich SimpleImputer, drop(), ... an

Data Cleaning

```
In [35]: from sklearn.impute import SimpleImputer
         imputer = SimpleImputer(strategy="median")
```

Remove the text attribute because median can only be calculated on numerical attributes:

```
In [36]: housing_num = housing.drop("ocean_proximity", axis=1)
         # alternatively: housing_num = housing.select_dtypes(include=[np.number])
```

```
In [37]: imputer.fit(housing_num)
```

```
Out[37]: SimpleImputer(strategy='median')
```

```
In [38]: imputer.statistics_
```

```
Out[38]: array([-118.51 ,  34.26 ,  29.    , 2119.5   ,  433.    , 1164.    ,
                408.    ,  3.5409])
```

Transform the training set:

```
In [40]: X = imputer.transform(housing_num)
```

```
In [42]: housing_tr = pd.DataFrame(X, columns=housing_num.columns,
                                   index=housing_num.index)
```

```
In [43]: housing_tr.head()
```

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Bearbeiten von Text und kategorischen Merkmalen

- Kategorische Merkmale müssen Sie vorverarbeiten, da für ML-Methoden zwischen zwei Werten eines Merkmals eine numerische Metrik (ein Abstand) definiert sein muss
- Bsp.:
 - Das Merkmal `ocean_proximity` in unserem Datensatz

```
ocean_proximity
<1H OCEAN
<1H OCEAN
NEAR OCEAN
INLAND
<1H OCEAN
INLAND
<1H OCEAN
INLAND
<1H OCEAN
<1H OCEAN
```

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Bearbeiten von Text und kategorischen Merkmalen

- Kategorische Merkmale müssen Sie vorverarbeiten, da für ML-Methoden zwischen zwei Werten eines Merkmals eine numerische Metrik (ein Abstand) definiert sein muss
- Bsp.:
 - Das Merkmal `ocean_proximity` in unserem Datensatz

```
ocean_proximity
<1H OCEAN
<1H OCEAN
NEAR OCEAN
INLAND
<1H OCEAN
INLAND
<1H OCEAN
INLAND
<1H OCEAN
<1H OCEAN
```

Klassen in scikit-learn:

- `OrdinalEncoder` → wandelt Kategorien in die Zahlen 0, 1, 2, ... um
 - Nur nutzen, wenn es eine Metrik für die Kategorien gibt, bspw. die Kategorien „schlecht“, „durchschnittlich“ und „gut“

- Bsp.:
 - „<1H OCEAN“ → 0,
 - „NEAR OCEAN“ → 1,
 - „INLAND“ → 2, ...

Bsp.:
„schlecht“ → 0,
„durchschnittlich“ → 1,
„gut“ → 2, ...

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Bearbeiten von Text und kategorischen Merkmalen

- Kategorische Merkmale müssen Sie vorverarbeiten, da für ML-Methoden zwischen zwei Werten eines Merkmals eine numerische Metrik (ein Abstand) definiert sein muss
- Bsp.:
 - Das Merkmal `ocean_proximity` in unserem Datensatz

```
ocean_proximity
<1H OCEAN
<1H OCEAN
NEAR OCEAN
INLAND
<1H OCEAN
INLAND
<1H OCEAN
INLAND
<1H OCEAN
<1H OCEAN
```

Klassen in scikit-learn:

- `OrdinalEncoder` → wandelt Kategorien in die Zahlen 0, 1, 2, ... um
 - Nur nutzen, wenn es eine Metrik für die Kategorien gibt, bspw. die Kategorien „schlecht“, „durchschnittlich“ und „gut“
- `OneHotEncoder` → Jede Kategorie wird durch einen K-dimensionalen Vektor dargestellt, der nur an einer Stelle eine 1 hat, Rest 0. K ist die Anzahl der Kategorien.

```
array([[0., 0., 0., 0., 1.],
       [0., 0., 0., 0., 1.],
       [0., 0., 0., 1., 0.],
       ...,
       [0., 1., 0., 0., 0.],
       [0., 1., 0., 0., 0.],
       [1., 0., 0., 0., 0.]])
```


Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Bearbeiten von Text und kategorischen Merkmalen

- OneHotEncoder → Jede Kategorie wird durch einen K-dimensionalen Vektor dargestellt, der nur an einer Stelle eine 1 hat, Rest 0. K ist die Anzahl der Kategorien.
- Abstand zwischen jeder Kategorie ist damit gleich
- Jede Kategorie wird zu einem eigenen binären Merkmal

	ocean_proximity_<1H OCEAN	ocean_proximity_INLAND	ocean_proximity_ISLAND	ocean_proximity_NEAR BAY	ocean_proximity_NEAR OCEAN
14196	0.0	0.0	0.0	0.0	1.0
8267	0.0	0.0	0.0	0.0	1.0
17445	0.0	0.0	0.0	1.0	0.0
14265	1.0	0.0	0.0	0.0	0.0
2271	0.0	1.0	0.0	0.0	0.0

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Übung - Bearbeiten von Text und kategorischen Merkmalen

- Schauen Sie sich die Klassen OneHotEncoder, ... an

```
In [45]: ▶ from sklearn.preprocessing import OneHotEncoder  
  
cat_encoder = OneHotEncoder()  
housing_cat_1hot = cat_encoder.fit_transform(housing_cat)  
housing_cat_1hot
```

```
Out[45]: <16512x5 sparse matrix of type '<class 'numpy.float64'>'  
        with 16512 stored elements in Compressed Sparse Row format>
```


By default, the `OneHotEncoder` class returns a sparse array, but we can convert it to a dense array if needed by calling the `toarray()` method:

```
In [46]: ▶ housing_cat_1hot.toarray()  
  
Out[46]: array([[1., 0., 0., 0., 0.],  
                [1., 0., 0., 0., 0.],  
                [0., 0., 0., 0., 1.],  
                ...,  
                [0., 1., 0., 0., 0.],  
                [1., 0., 0., 0., 0.],  
                [0., 0., 0., 1., 0.]])
```

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Feature Engineering (Teil 2)

- Normalisierung einer linksschiefen Verteilung eines Merkmals durch Logarithmieren
 - Warum macht man das?
 - Manche ML-Algorithmen gehen von Gauß-verteilten Merkmalen aus
 - Hilft bei der Konvergenz der ML-Algorithmen



Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Feature Engineering (Teil 2)

- Logarithmisch transformiertes Merkmal:

```
from sklearn.preprocessing import FunctionTransformer  
  
log_transformer = FunctionTransformer(np.log, inverse_func=np.exp)  
log_pop = log_transformer.transform(housing[["population"]])
```

- Äquivalent zu:
 - `np.log(housing[["population"]])`

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Skalieren von Merkmalen

- Die meisten Machine Learning Methoden können nicht mit beliebig (vor allem sehr unterschiedlich) skalierten Merkmalen arbeiten
- Deshalb sollten Sie fast immer die Merkmale in einen Wertebereich von bspw. 0 bis 1 oder -1 bis 1 bringen
- MinMaxScaler → Min-Max-Skalierung (Normalisieren)
 - Merkmale sind dann zwischen 0 und 1 skaliert
 - Anfällig gegenüber Ausreißer

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor


Skalieren von Merkmalen

- Die meisten Machine Learning Methoden können nicht mit beliebig (vor allem sehr unterschiedlich) skalierten Merkmalen arbeiten
- Deshalb sollten Sie fast immer die Merkmale in einen Wertebereich von bspw. 0 bis 1 oder -1 bis 1 bringen
- MinMaxScaler → Min-Max-Skalierung (Normalisieren)
 - Merkmale sind dann zwischen 0 und 1 skaliert
 - Anfällig gegenüber Ausreißer
- StandardScaler → Standardisierung
 - Mittelwert abziehen und durch Standardabweichung dividieren
 - Mittelwert ist 0, Varianz ist 1
- Scikit-learn hat weitere Scaler

$$x_{\text{norm},i} := \frac{x_i - \bar{x}}{\sigma}$$


Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Skalieren von Merkmalen



Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

- Aufbereiten der Daten
- Bearbeiten von Text und kategorischen Merkmalen
- Skalieren von Merkmalen
- Pipelines zur Transformation
 - Leitfrage: Wie können wir die Datenaufbereitung übersichtlich als Pipeline programmieren?



Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Das Design von Scikit-Learn

- Estimatoren
 - Jedes Objekt, das Parameter anhand eines Datensatzes abschätzen kann
 - Bspw.: Imputer, Encoder, Scaler
 - Besitzt die Methode `fit()`
- Transformer
 - Ein Estimator, der den übergebenen Datensatz außerdem transformieren kann
 - Bspw.: Imputer, Encoder, Scaler
 - Besitzt die Methoden `fit()` und `transform()`; `fit_transform()` führt beide hintereinander aus
- Prädiktoren
 - Estimator, der auf dem gegebenen Datensatz Vorhersagen treffen kann
 - Bspw.: LinearRegression
 - Besitzt die Methoden `fit()`, `predict()` und `score()`

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Pipelines zur Transformation

- Zur sequentiellen Ausführung der verschiedenen Transformationen gibt es in Scikit-Learn die Klasse Pipeline
- Benötigt eine Liste von Name-Estimator-Paaren, die die Abfolge der einzelnen Schritte definiert
- Aufruf von `fit_transform()` ruft `fit_transform()` für alle Transformer sequentiell auf.
- Ausgabe ist Eingabe des nächsten Schritts.
- Vorteil:
 - Datenvorverarbeitung wird transparenter und kann direkt auf neue Daten angewendet werden

```
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
```

```
num_pipeline = Pipeline([
    ("impute", SimpleImputer(strategy="median")),
    ("standardize", StandardScaler()),
])
```

```
housing_num_tr = num_pipeline.fit_transform(housing_num)
```

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Pipelines zur Transformation

- Pipeline für kategoriale Merkmale:
- Imputation: Ersetze fehlende Daten mit der am häufigsten auftretenden Kategorie des Merkmals

```
cat_attribs = ["ocean_proximity"]


cat_pipeline = make_pipeline(
    SimpleImputer(strategy="most_frequent"),
    OneHotEncoder(handle_unknown="ignore"))
```

```
cat_pipeline.fit_transform(housing_cat)
```

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Pipelines zur Transformation

- Zusammenführung von numerischen und kategorischen Merkmalen:
- ColumnTransformer



```
from sklearn.compose import ColumnTransformer
```

```
num_attribs = list(housing_num)
cat_attribs = ["ocean_proximity"]
```

```
preprocessing = ColumnTransformer([
    ("num", num_pipeline, num_attribs),
    ("cat", cat_pipeline, cat_attribs),
])
```

```
housing_prepared = preprocessing.fit_transform(housing)
```

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Pipelines zur Transformation

- Zusammenführung von numerischen und kategorischen Merkmalen:

num__population	num__households	num__median_income	cat__ocean_proximity_<1H OCEAN	cat__ocean_proximity_INLAND
1.081011	1.507507	0.379698	0.0	0.0
-0.643842	-0.878707	0.420068	0.0	0.0

Bereiten Sie die Daten für Machine-Learning-Algorithmen vor

Übung - Pipelines zur Transformation

- Programmieren Sie eine Pipeline für Ihren Datensatz
- 10 Min.

```
from sklearn.compose import make_column_selector

def column_ratio(X):
    return X[:, [0]] / X[:, [1]]

def ratio_name(function_transformer, feature_names_in):
    return ["ratio"] # feature names out

def ratio_pipeline():
    return make_pipeline(
        SimpleImputer(strategy="median"),
        FunctionTransformer(column_ratio, feature_names_out=ratio_name),
        StandardScaler())

log_pipeline = make_pipeline(
    SimpleImputer(strategy="median"),
    FunctionTransformer(np.log, feature_names_out="one-to-one"),
    StandardScaler())

default_num_pipeline = make_pipeline(SimpleImputer(strategy="median"),
                                     StandardScaler())

preprocessing = ColumnTransformer([
    ("bedrooms", ratio_pipeline(), ["total_bedrooms", "total_rooms"]),
    ("rooms_per_house", ratio_pipeline(), ["total_rooms", "households"]),
    ("people_per_house", ratio_pipeline(), ["population", "households"]),
    ("log", log_pipeline, ["total_bedrooms", "total_rooms", "population",
                           "households", "median_income"]),
    ("cat", cat_pipeline, make_column_selector(dtype_include=object)),
],
    remainder=default_num_pipeline) # columns remaining: lat, lon, housing_median_age
```

Lernraum I: Wie wird ein Machine Learning Projekt durchgeführt?

- Ein Machine Learning Projekt von A bis Z
 - Klären Sie die Aufgabenstellung und betrachten Sie die Gesamtsituation
 - Beschaffen Sie sich Daten
 - Erkunden und visualisieren Sie die Daten, um daraus Erkenntnisse zu gewinnen
 - Bereiten Sie die Daten so auf, dass Machine-Learning-Algorithmen die Muster darin leichter erkennen können
 - **Probieren Sie viele unterschiedliche Modelle aus und treffen Sie eine engere Auswahl**
 - Optimieren Sie Ihre Modelle und kombinieren Sie diese zu einer guten Lösung
 - Stellen Sie Ihre Lösung vor
 - Starten, beobachten und warten Sie Ihr System


Wähle ein Modell aus und trainiere es

- Trainieren und Auswerten auf dem Trainingsdatensatz
- Was ist ein Validierungsdatensatz?
- Kreuzvalidierung

Wähle ein Modell aus und trainiere es

Trainieren und Auswerten auf dem Trainingsdatensatz

■ LinearRegression



```
from sklearn.linear_model import LinearRegression
```

```
lin_reg = LinearRegression()  
lin_reg.fit(housing_prepared, housing_labels)
```

```
from sklearn.metrics import mean_squared_error  
housing_predictions = lin_reg.predict(housing_prepared)  
lin_mse = mean_squared_error(housing_labels, housing_predictions)
```


■ DecisionTreeRegressor

```
from sklearn.tree import DecisionTreeRegressor  
tree_reg = DecisionTreeRegressor()  
tree_reg.fit(housing_prepared, housing_labels)
```

Wähle ein Modell aus und trainiere es


Trainieren und Auswerten auf dem Trainingsdatensatz - Entscheidungsbaum

- Decision Tree
- Überlebenswahrscheinlichkeit auf der Titanic
- Modell wird aus Trainingsdaten gelernt



Wähle ein Modell aus und trainiere es


Trainieren und Auswerten auf dem Trainingsdatensatz - Entscheidungsbaum



Wähle ein Modell aus und trainiere es

Trainieren und Auswerten auf dem Trainingsdatensatz – Random Forest

- RandomForestRegressor



Wähle ein Modell aus und trainiere es

Übung

- Trainieren Sie ein RandomForestRegressor auf Ihrem Trainingsdatensatz
- Wie groß ist der Prädiktionsfehler auf den Trainingsdaten?
- 10 Min.

```
In [63]: from sklearn.tree import DecisionTreeRegressor
```

```
tree_reg = DecisionTreeRegressor(random_state=42)  
tree_reg.fit(housing_prepared, housing_labels)
```

```
Out[63]: DecisionTreeRegressor(random_state=42)
```

```
In [64]: housing_predictions = tree_reg.predict(housing_prepared)  
tree_rmse = mean_squared_error(housing_labels, housing_predictions,  
                               squared=False)  
  
tree_rmse
```

```
Out[64]: 0.0
```

```
# TODO: importieren Sie RandomForestRegressor und trainieren Sie einen Random Forest auf den vorverarbeiteten Daten
```


```
# TODO: machen Sie Vorhersagen auf den Trainingsdaten und berechnen Sie deren RMSE, nennen Sie den RMSE forest_rmse.  
# Vergleichen Sie forest_rmse mit tree_rmse  
# forest_rmse
```

Wähle ein Modell aus und trainiere es

- Trainieren und Auswerten auf dem Trainingsdatensatz
- Was ist ein Validierungsdatensatz?
- Kreuzvalidierung
- Leitfrage:
 - Wie können wir abschätzen wie gut das Modell auf den Testdaten performen wird ohne es zu testen?

Wähle ein Modell aus und trainiere es


Was ist der Validierungsdatensatz?



Wähle ein Modell aus und trainiere es

Was ist der Validierungsdatensatz?


- Der Validierungsdatensatz wird aus dem Trainingsdatensatz erstellt
- Validierungsdatensatz und Trainingsdatensatz (nach der Abtrennung des Validierungsdatensatzes) sind disjunkt
- Die Berechnung des Prädiktionsfehlers der Modellvorhersagen auf dem Validierungsdatensatz, gibt eine etwas bessere Schätzung über den zu erwartenden Testfehler ab



Wähle ein Modell aus und trainiere es

Kreuzvalidierung

- Um eine robustere Schätzung für den zu erwartenden Testfehler des Machine Learning Modells zu erhalten, macht man den Trainings-/Validierungssplit nicht nur einmal, sondern k-mal.
- k-fache Kreuzvalidierung (k-fold Cross Validation):
 - k disjunkte Teilmengen aus dem Trainingsdatensatz
 - Verwende k-1 für Training und 1 für Validierung
 - k Trainingsdurchläufe



Bsp.: 4-fache Kreuzvalidierung

Wähle ein Modell aus und trainiere es

Kreuzvalidierung

- `cross_val_score`

```
from sklearn.tree import DecisionTreeRegressor
tree_reg = DecisionTreeRegressor()

from sklearn.model_selection import cross_val_score
scores = cross_val_score(tree_reg, housing_prepared, housing_labels,
                        scoring="neg_mean_squared_error", cv=10)
tree_rmse_scores = np.sqrt(-scores)
```

Wähle ein Modell aus und trainiere es

Kreuzvalidierung - Übung

- Trainieren und validieren Sie den RandomForestRegressor mittels Kreuzvalidierung
 - Vergleichen Sie den mittleren Validierungsfehler mit dem Trainingsfehler

```
from sklearn.ensemble import RandomForestRegressor

forest_reg = make_pipeline(preprocessing,
                           RandomForestRegressor(random_state=42))
forest_rmses = -cross_val_score(forest_reg, housing, housing_labels,
                                scoring="neg_root_mean_squared_error", cv=2)
```

```
pd.Series(forest_rmses).describe()
```

```
count      2.000000
mean     49128.717554
std       748.944859
min      48599.133565
25%      48863.925560
50%      49128.717554
75%      49393.509548
max      49658.301543
dtype: float64
```

```
from sklearn.ensemble import RandomForestRegressor
```

```
# TODO: führen Sie eine Kreuzvalidierung für RandomForestRegressor aus und speichern Sie die RMSE-Werte der einzelnen Forests
# in forest_rmses
```

Wähle ein Modell aus und trainiere es

- Abspeichern eines trainierten Machine Learning Modells

```
import joblib

joblib.dump(my_model, "my_model.pkl")
# und später ...
my_model_loaded = joblib.load("my_model.pkl")
```

Lernraum I: Wie wird ein Machine Learning Projekt durchgeführt?

- Ein Machine Learning Projekt von A bis Z
 - Klären Sie die Aufgabenstellung und betrachten Sie die Gesamtsituation
 - Beschaffen Sie sich Daten
 - Erkunden und visualisieren Sie die Daten, um daraus Erkenntnisse zu gewinnen
 - Bereiten Sie die Daten so auf, dass Machine-Learning-Algorithmen die Muster darin leichter erkennen können
 - Probieren Sie viele unterschiedliche Modelle aus und treffen Sie eine engere Auswahl
 - **Optimieren Sie Ihre Modelle und kombinieren Sie diese zu einer guten Lösung**
 - Stellen Sie Ihre Lösung vor
 - Starten, beobachten und warten Sie Ihr System

Optimiere das Modell

- Optimierung der Hyperparameter
- Gittersuche
- Random Search
- Analysiere die besten Modelle und ihre Fehler
- Evaluation auf dem Testdatensatz

Optimiere das Modell

Wähle optimale Hyperparameter auf Basis des Validierungsdatensatzes

- Hyperparameter bei einem Machine Learning Algorithmus können sein:
 - Random Forest: Anzahl Entscheidungsbäume, maximale Tiefe der Entscheidungsbäume
 - Optimierungsalgorithmus, Schrittweite (Lernrate)
 - Art der Datenvorverarbeitung (bspw. Skalierung der Merkmale, Daten Imputation)
 - ...
- Validierungsdatensatz wird zur Bestimmung optimaler Hyperparameter des Machine Learning Algorithmus genutzt

Optimiere das Modell

Wähle optimale Hyperparameter auf Basis des Validierungsdatensatzes

Parameters:

n_estimators : int, default=100

The number of trees in the forest.

Changed in version 0.22: The default value of `n_estimators` changed from 10 to 100 in 0.22.

criterion : {"squared_error", "absolute_error", "friedman_mse", "poisson"}, default="squared_error"

The function to measure the quality of a split. Supported criteria are "squared_error" for the mean squared error, which is equal to variance reduction as feature selection criterion and minimizes the L2 loss using the mean of each terminal node, "friedman_mse", which uses mean squared error with Friedman's improvement score for potential splits, "absolute_error" for the mean absolute error, which minimizes the L1 loss using the median of each terminal node, and "poisson" which uses reduction in Poisson deviance to find splits. Training using "absolute_error" is significantly slower than when using "squared_error".

New in version 0.18: Mean Absolute Error (MAE) criterion.

New in version 1.0: Poisson criterion.

max_depth : int, default=None

The maximum depth of the tree. If None, then nodes are expanded until all leaves are pure or until all leaves contain less than `min_samples_split` samples.

min_samples_split : int or float, default=2


The minimum number of samples required to split an internal node:

- If int, then consider `min_samples_split` as the minimum number.
- If float, then `min_samples_split` is a fraction and `ceil(min_samples_split * n_samples)` are the minimum number of samples for each split.

<https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html>

Optimiere das Modell


Wähle optimale Hyperparameter auf Basis des Validierungsdatensatzes



Optimiere das Modell

Kreuzvalidierung

- Um ein robusteres Machine Learning Modell zu erhalten, macht man den Trainings-/Validierungssplit nicht nur einmal, sondern k-mal.
- k-fache Kreuzvalidierung (k-fold Cross Validation):
 - k disjunkte Teilmengen aus dem Trainingsdatensatz
 - Verwende k-1 für Training und 1 für Validierung
 - k Trainingsdurchläufe
- Pro Hyperparameter erhält man k Ergebnisse
 - Mittelwert, Standardabweichung, etc. über die k Ergebnisse (Genauigkeit, ...) sind ein robustes Maß für die Qualität des Hyperparameters



Bsp.: 4-fache Kreuzvalidierung


Optimiere das Modell

Optimierung der Hyperparameter - Gittersuche

- Angabe der zu optimierenden Hyperparameter und deren Wertebereiche

```
param_grid = [  
    {'n_estimators': [3, 10, 30], 'max_features': [2, 4, 6, 8]},  
  
]
```

- GridSearchCV
 - Evaluiert alle möglichen Kombinationen der Hyperparameter über eine Kreuzvalidierung



Optimiere das Modell

Gittersuche

```
from sklearn.model_selection import GridSearchCV

full_pipeline = Pipeline([
    ("preprocessing", preprocessing),
    ("random_forest", RandomForestRegressor(random_state=42)),
])
```

```
param_grid = [
    {'random_forest__max_features': [4, 8, 10]},
]

grid_search = GridSearchCV(full_pipeline, param_grid, cv=2,
                           scoring='neg_root_mean_squared_error')


grid_search.fit(housing, housing_labels)
```

Optimiere das Modell

Optimierung der Hyperparameter - Zufällige Suche


- RandomizedSearchCV
 - Zufällig gewählte Werte für die Hyperparameter werden evaluiert
 - Man kann angeben wie viele Durchläufe gemacht werden sollen
- Werte der besten Hyperparameter:
 - `grid_search.best_params_`
- Das beste Machine Learning Modell
 - `grid_search.best_estimator_`

Hyperparameter 2



Hyperparameter 1

Hyperparameter 2



Hyperparameter 1

Optimiere das Modell

Optuna: A hyperparameter optimization framework

- <https://github.com/optuna/optuna>

```
def objective(trial):
    iris = sklearn.datasets.load_iris()
    x, y = iris.data, iris.target

    classifier_name = trial.suggest_categorical("classifier", ["SVC", "RandomForest"])
    if classifier_name == "SVC":
        svc_c = trial.suggest_float("svc_c", 1e-10, 1e10, log=True)
        classifier_obj = sklearn.svm.SVC(C=svc_c, gamma="auto")
    else:
        rf_max_depth = trial.suggest_int("rf_max_depth", 2, 32, log=True)
        classifier_obj = sklearn.ensemble.RandomForestClassifier(
            max_depth=rf_max_depth, n_estimators=10
        )

    score = sklearn.model_selection.cross_val_score(classifier_obj, x, y, n_jobs=-1, cv=3)
    accuracy = score.mean()
    return accuracy

if __name__ == "__main__":
    study = optuna.create_study(direction="maximize")
    study.optimize(objective, n_trials=100)
    print(study.best_trial)
```

Optimiere das Modell

Übung

- Führen Sie eine Hyperparameteroptimierung für den DecisionTreeRegressor durch
- 10 Min.

```
In [69]: from sklearn.model_selection import GridSearchCV

param_grid = [
    # try 4 values of hyperparameters
    {'max_features': [2, 4, 6, 8]},
]

tree_reg = DecisionTreeRegressor(random_state=42)
# train across 5 folds, that's a total of (12+6)*5=90 rounds of training
grid_search = GridSearchCV(tree_reg, param_grid, cv=5,
                           scoring='neg_mean_squared_error',
                           return_train_score=True)
grid_search.fit(housing_prepared, housing_labels)
```

```
Out[69]: GridSearchCV(cv=5, estimator=DecisionTreeRegressor(random_state=42),
                      param_grid=[{'max_features': [2, 4, 6, 8]}],
                      return_train_score=True, scoring='neg_mean_squared_error')
```

The best hyperparameter combination found:

```
In [70]: grid_search.best_params_
```

```
Out[70]: {'max_features': 8}
```

```
In [71]: grid_search.best_estimator_
```

```
Out[71]: DecisionTreeRegressor(max_features=8, random_state=42)
```


Optimiere das Modell

Analysiere die besten Modelle und ihre Fehler

■ feature_importances_

```
final_model = rnd_search.best_estimator_ # includes preprocessing
feature_importances = final_model["random_forest"].feature_importances_
feature_importances.round(2)
```

```
array([0.07, 0.06, 0.1 , 0.02, 0.02, 0.02, 0.02, 0.32, 0.01, 0.15, 0. ,
       0. , 0.01, 0.08, 0.07, 0.04])
```




```
sorted(zip(feature_importances,
           final_model["preprocessing"].get_feature_names_out()),
       reverse=True)
```

```
... [(np.float64(0.31886048133755257), 'log__median_income'),
      (np.float64(0.1510583262368883), 'cat__ocean_proximity_INLAND'),
      (np.float64(0.10453532964301888), 'people_per_house__ratio'),
      (np.float64(0.07854000249145283), 'remainder__longitude'),
      (np.float64(0.07378674724936723), 'bedrooms__ratio'),
      (np.float64(0.0711433737618508), 'remainder__latitude'),
      (np.float64(0.0625183928781416), 'rooms_per_house__ratio'),
      (np.float64(0.04162563450358223), 'remainder__housing_median_age'),
      (np.float64(0.01941020584160027), 'log__population'),
      (np.float64(0.019378351600314342), 'log__total_rooms'),
      (np.float64(0.01796568228240626), 'log__households'),
      (np.float64(0.017909045391759148), 'log__total_bedrooms'),
      (np.float64(0.014385110310661205), 'cat__ocean_proximity<1H_OCEAN')]
```

Optimiere das Modell

Analysiere die besten Modelle und ihre Fehler

- Weights & Biases
- <https://wandb.ai/site>



Optimiere das Modell

Evaluere das Machine Learning System auf dem Testdatensatz

- Wenn Sie glücklich mit Ihrem Modell sind, dann können Sie jetzt **einmal**:
 - Testdatensatz mit Pipeline transformieren und dann mit **finalem** Modell Vorhersagen machen
 - Hier ist Datentransformation und finales Modell bereits in der Pipeline `final_model` gespeichert

```
X_test = test_set.drop("median_house_value", axis=1)
y_test = test_set["median_house_value"].copy()

final_predictions = final_model.predict(X_test)

# Calculate Mean Squared Error (MSE) first
final_mse = mean_squared_error(y_test, final_predictions)
# Then take the square root to get Root Mean Squared Error (RMSE)
final_rmse = np.sqrt(final_mse)
print(final_rmse)
```

Optimiere das Modell

Übung - Evaluiere das Machine Learning System auf dem Testdatensatz

- Transformieren Sie den Testdatensatz mit Pipeline und machen Sie mit **finalem** Modell Vorhersagen
- 10 Min.

```
X_test = test_set.drop("median_house_value", axis=1)
y_test = test_set["median_house_value"].copy()

final_predictions = final_model.predict(X_test)

# Calculate Mean Squared Error (MSE) first
final_mse = mean_squared_error(y_test, final_predictions)
# Then take the square root to get Root Mean Squared Error (RMSE)
final_rmse = np.sqrt(final_mse)
print(final_rmse)
```

Lernraum I: Wie wird ein Machine Learning Projekt durchgeführt?

- Ein Machine Learning Projekt von A bis Z
 - Klären Sie die Aufgabenstellung und betrachten Sie die Gesamtsituation
 - Beschaffen Sie sich Daten
 - Erkunden und visualisieren Sie die Daten, um daraus Erkenntnisse zu gewinnen
 - Bereiten Sie die Daten so auf, dass Machine-Learning-Algorithmen die Muster darin leichter erkennen können
 - Probieren Sie viele unterschiedliche Modelle aus und treffen Sie eine engere Auswahl
 - Optimieren Sie Ihre Modelle und kombinieren Sie diese zu einer guten Lösung
 - **Stellen Sie Ihre Lösung vor**
 - Starten, beobachten und warten Sie Ihr System

Stellen Sie Ihre Lösung vor

- Dokumentieren Sie Ihr Werk
- Erstellen Sie eine ansprechende Präsentation
 - Heben Sie zu Beginn das Gesamtbild hervor
 - Stimmen Sie die Inhaltstiefe auf Ihre Zielgruppe ab
- Erklären Sie, warum Ihre Lösung zum Geschäftsziel beiträgt
- Vergessen Sie nicht, auf dem Weg gewonnene interessante Erkenntnisse zu erwähnen
 - Beschreiben Sie, was funktioniert hat und was nicht
 - Zählen Sie Ihre Annahmen und die Beschränkungen Ihres Systems auf
- Stellen Sie sicher, dass Ihre wichtigsten Erkenntnisse durch eine ansprechende Visualisierung oder eingängige Aussagen untermauert werden (z.B. »das mittlere Einkommen hat den stärksten Einfluss bei der Vorhersage von Immobilienpreisen«)

Lernraum I: Wie wird ein Machine Learning Projekt durchgeführt?


- Ein Machine Learning Projekt von A bis Z
 - Klären Sie die Aufgabenstellung und betrachten Sie die Gesamtsituation
 - Beschaffen Sie sich Daten
 - Erkunden und visualisieren Sie die Daten, um daraus Erkenntnisse zu gewinnen
 - Bereiten Sie die Daten so auf, dass Machine-Learning-Algorithmen die Muster darin leichter erkennen können
 - Probieren Sie viele unterschiedliche Modelle aus und treffen Sie eine engere Auswahl
 - Optimieren Sie Ihre Modelle und kombinieren Sie diese zu einer guten Lösung
 - Stellen Sie Ihre Lösung vor
 - **Starten, beobachten und warten Sie Ihr System**

Starten, beobachten und warten Sie Ihr System

- Wo soll das Modell laufen?

- Webserver

- Google Cloud AI Platform
 - JSON-Requests und Responses
 - TFX, TensorFlow Serving



- Mikrocontroller

- Kompression des Modells (Quantisierung)
 - Für neuronale Netze → TensorFlow Lite, Edge Impulse, ...

- Browser

- TensorFlow.js




Starten, beobachten und warten Sie Ihr System

- Überwachen der Qualität des Modells
 - Verändern sich die Eingangsdaten?
 - Modell regelmäßig Nachtrainieren, wenn mehr Daten zur Verfügung stehen
- MLOps → DevOps für Machine Learning


Starten, beobachten und warten Sie Ihr System

MLOps



Starten, beobachten und warten Sie Ihr System

Hidden Technical Debt in Machine Learning Systems



Lernraum I: Wie wird ein Machine Learning Projekt durchgeführt?

Zusammenfassung und Fragen

- Ein Machine Learning Projekt von A bis Z
 - Klären Sie die Aufgabenstellung und betrachten Sie die Gesamtsituation
 - Beschaffen Sie sich Daten
 - Erkunden und visualisieren Sie die Daten, um daraus Erkenntnisse zu gewinnen
 - Bereiten Sie die Daten so auf, dass Machine-Learning-Algorithmen die Muster darin leichter erkennen können
 - Probieren Sie viele unterschiedliche Modelle aus und treffen Sie eine engere Auswahl
 - Optimieren Sie Ihre Modelle und kombinieren Sie diese zu einer guten Lösung
 - Stellen Sie Ihre Lösung vor
 - Starten, beobachten und warten Sie Ihr System

Nächste Vorlesung und Fragen

- Neuronale Netze und Deep Learning
- Fragen?