

Vorabfragen

- Sie müssen ein KI-System für die Kreditvergabe entwickeln. Welches Modell würden Sie bevorzugen?
 - A) Ein Entscheidungsbaum mit 85 % Genauigkeit
 - B) Ein Deep-Learning-Modell mit 92 % Genauigkeit, dessen Entscheidungen niemand nachvollziehen kann
- ChatGPT beantwortet eine Frage falsch. Welche zusätzliche Information würde Ihnen am meisten helfen?
 - Trainingsdaten
 - Modellarchitektur
 - Quellen bzw. Begründung der Antwort
 - Konfidenz der Antwort



Deep Learning, Machine Learning und Künstliche Intelligenz – SS 26

Gelesen von Prof. Dr. Daniel Gaida

Lernraum III

Explainable AI (XAI) – Erklärbare KI

- Warum möchten wir, dass uns eine KI ihre Entscheidung erklärt?
 - Für wen ist die Erklärung?
- Was ist Erklärbare KI?

- Intrinsisch erklärbare Machine Learning Modelle
- Post-hoc-Methoden
 - LIME
 - SHAP

- Erklärungen heutiger Systeme

Lernziele von heute und Fragen zur Überprüfung der Lernziele

WAS:

Die Studierenden können einfache XAI-Methoden mit Hintergrundwissen nutzen und bewerten.

WOMIT:

Dies geschieht durch die Vorstellung typischer Anwendungsfelder für Explainability, den Vergleich intrinsischer und post-hoc Verfahren (z. B. Entscheidungsbaum vs. LIME) und die Analyse derer Ergebnisse.

WOZU:

Die Studierenden sind dadurch in der Lage, die Auswahl und Anwendung von Erklärungen als Teil von KI-Systemen kritisch zu gestalten und für unterschiedliche Zielgruppen angemessene Erklärungen zu identifizieren.

s. Übungsaufgaben von heute

Warum möchten wir, dass uns eine KI ihre Entscheidung erklärt?

- Haben Sie schon mal eine Entscheidung durch ein KI-System erhalten, die Sie nicht verstanden haben?

Beispiele zur Diskussion:


- ChatGPT liefert „falsche“ Antwort, aber sagt nicht warum
- Kredit-Scoring: Warum abgelehnt?
- Studienberatung: Empfehlung unklar
- YouTube/Spotify/Amazon/Netflix: Warum wird mir das empfohlen?

Warum möchten wir, dass uns eine KI ihre Entscheidung erklärt?

Diskussion

Wie erklärt Netflix, warum ein Film/eine Serie dem Nutzer empfohlen wird?


Glauben Sie, dass diese Erklärung den Nutzern hilft?



Source: www.netflix.com


The Black Box Problem of Machine Learning

Quelle: Introduction to Intelligent User Interfaces, Sarah Theres Völkel, LMU, 2020




The Black Box Problem of Machine Learning

Quelle: Introduction to Intelligent User Interfaces, Sarah Theres Völkel, LMU, 2020




The Black Box Problem of Machine Learning

Quelle: Introduction to Intelligent User Interfaces, Sarah Theres Völkel, LMU, 2020




The Black Box Problem of Machine Learning

Quelle: Introduction to Intelligent User Interfaces, Sarah Theres Völkel, LMU, 2020



The Black Box Problem of Machine Learning

Quelle: Introduction to Intelligent User Interfaces, Sarah Theres Völkel, LMU, 2020



Erklärungen für KI-Entwickler

Modell-Validierung

Quelle: Introduction to Intelligent User Interfaces, Sarah Theres Völkel, LMU, 2020



Source: Brandon Messner | Unsplash

Classified as Dog - correct



Source: Jose Carls Ichiro | Unsplash

Classified as Wolf - correct

Erklärungen für KI-Entwickler

Modell-Validierung

Quelle: Introduction to Intelligent User Interfaces, Sarah Theres Völkel, LMU, 2020



Source: Kateryna Babaieva | Pexels

Classified as Wolf – false (Husky)



Source : Kateryna Babaieva | Pexels, adapted after [Ribeiro et al. 2016]

LIME-Explanation (idealised)

Warum möchten wir, dass uns eine KI ihre Entscheidung erklärt?

- Menschliche Neugierde und Lernen
 - Erklärungen stillen unser Bedürfnis nach Wissen und helfen uns, unerwartete Ergebnisse zu verstehen.
- Sinn in der Welt finden
 - Erklärungen helfen uns, Widersprüche zwischen Erwartung und Realität aufzulösen.
 - Beispiel: Person wird ein Kreditantrag abgelehnt, obwohl sie eine gute Bonität hat. Erst durch eine Erklärung kann diese Diskrepanz verstanden werden.
- Soziale Akzeptanz von KI erhöhen
 - Transparente Systeme schaffen Vertrauen und erleichtern die Integration von KI in unseren Alltag.

Was ist Explainable AI?

Definition:

- Explainable AI (XAI) umfasst alle Ansätze, die darauf zielen, **menschlich verständliche Gründe** für die Entscheidungen eines KI-Systems bereitzustellen.

Begriff	Bedeutung
Whitebox-Modell	Modell ist grundsätzlich durchschaubar (z. B. kleiner Entscheidungsbaum)
Blackbox-Modell	Struktur + Logik sind für Menschen nicht direkt verständlich (z. B. Deep Learning)
Erklärung	Zusatzinformationen zur Entscheidung – verbal, visuell oder symbolisch (z.B. Regeln)

Transparenz vs Erklärbarkeit vs Interpretierbarkeit

Transparency

Provides documentation for the system's decisions and actions (details about model architecture, training data, optimizations, etc.) to ensure compliance and accountability

Examples: Model Cards, Datasheets for Datasets, Fairness Indicators, Algorithmic Impact Assessments

Interpretability

An interpretable model provides both visibility into its mechanisms and insight into how it arrives at its predictions. Provides insights into what features are important, how they are related, or what rules/patterns are learned.

Examples: Inherently Interpretable Models - Decision Trees

Explainability

Aims to make any AI system, including opaque deep learning models, more explainable. Involves developing techniques to explain the outputs/decisions of black-box AI models [usually] after they are trained.

Examples: Post-hoc Explanations - SHAP, Saliency Maps, Concept Activation Vectors

Transparenz

Quelle: Introduction to Intelligent User Interfaces, Sarah Theres Völkel, LMU, 2020

Why you're seeing an ad

When you see an ad from Google's network, you can see more details:

- **Google services**, like Google Search, YouTube, or Gmail: Click **Info** ⓘ > **Why This Ad**.
- **Non-Google websites and apps** that partner with Google to show ads: Click **AdChoices** ⓘ.
- For some ads on Google's network, you can click  **Paid for by** to learn additional information about the advertiser.

Reasons you might see an ad

- **Your info:**
 - Info in your Google Account, like your age range and gender
 - Your general location
- **Your activity:**
 - Your current search query
 - Previous search activity
 - Your activity while you were signed in to Google
 - Your previous interactions with ads
 - Types of websites you visit

Source: <https://adssettings.google.com>

Right to Explanation in the GDPR

Datenschutz-Grundverordnung (DSGVO)

Article 22

The data subject shall have the right **not to be subject to a decision based solely on automated processing**, including profiling, which produces legal effects concerning him or her or similarly significantly affects him or her.

[...]

..., the data controller shall implement suitable measures to safeguard the data subject's rights and freedoms and legitimate interests, at least the **right to obtain human intervention** on the part of the controller, **to express his or her point of view** and **to contest the decision**.

... trifft der für die Verarbeitung Verantwortliche geeignete Maßnahmen, um die Rechte und Freiheiten sowie die berechtigten Interessen der betroffenen Person zu wahren, zumindest das Recht, ein menschliches Eingreifen seitens des Verantwortlichen zu erwirken, ihren Standpunkt darzulegen und **die Entscheidung anzufechten**. [deepl]


Methoden der Erklärbarkeit

Quelle: Introduction to Intelligent User Interfaces, Sarah Theres Völkel, LMU, 2020

Intrinsisch erklärbare Modelle (Whitebox)

Post-hoc-Methoden (Blackbox-Erklärer)

Selbsterklärende Modelle, die die Interpretierbarkeit direkt in die Struktur integrieren




Methoden der Erklärbarkeit

Quelle: Introduction to Intelligent User Interfaces, Sarah Theres Völkel, LMU, 2020



Intrinsisch erklärbare Modelle (Whitebox)

Selbsterklärende Modelle, die die Interpretierbarkeit direkt in die Struktur integrieren



Post-hoc-Methoden (Blackbox-Erklärer)

Ein zweites Modell ist erforderlich, das Erklärungen für das trainierte Blackbox Modell liefert




Source: [Ribeiro et al. 2016]

Methoden der Erklärbarkeit

Intrinsisch erklärbare Modelle (Whitebox)

- Lineare Regression
- Logistische Regression
- Entscheidungsbaum (klein)



Beispiele

Lineare Regression

- Bsp.: Vorhersage Mietpreis (MP) von Wohnung:
- $MP(DZ, L) = -1.5 \cdot DZ - 0.5 \cdot L + 1050 \text{ €}$
- → Merkmal DZ (Distanz zum Zentrum/km) und L (Lärm/dB)


Entscheidungsbaum:

- Bsp.: Titanic: „Wenn Sie weiblich waren und nicht 3. Klasse gereist sind, dann hätten Sie mit Wahrscheinlichkeit von 93 % überlebt.“

<https://algobbeans.com/2016/07/27/decision-trees-tutorial/>


Logistische Regression

- Modell für Ja/Nein-Entscheidungen (binäre **Klassifikation**)
- Statt einer Geraden (wie bei linearer Regression) nutzt das Modell eine Sigmoid-Funktion
- Nutzt Merkmale (z. B. Alter, Einkommen, Lernzeit) zur Vorhersage von Wahrscheinlichkeiten
- Ergebnis: Wahrscheinlichkeit zwischen 0 und 1
→ Entscheidung durch Schwellwert (z. B. 0.5)



Methoden der Erklärbarkeit

Intrinsisch erklärbare Modelle (Whitebox)



Beispiele

Logistische Regression

- Bsp.: Vorhersage Kaufentscheidung von Wohnung (Ja/Nein):


- $$Wkt = \frac{1}{1 + \exp(-(-1.5DZ - 0.5L + 2.0))}$$

- DZ (Distanz zum Zentrum/km)
- L (Lärm/dB)

- Sigmoid-Funktion:
$$\frac{1}{1 + e^{-(\omega_0 + \omega_1 \cdot x)}}$$

Methoden der Erklärbarkeit

Intrinsisch erklärbare Modelle (Whitebox)



Beispiele

Logistische Regression

- Bsp.: Vorhersage Kaufentscheidung von Wohnung (Ja/Nein):

- $$Wkt = \frac{1}{1 + \exp(-(-1.5DZ - 0.5L + 2.0))}$$

- DZ (Distanz zum Zentrum/km)
- L (Lärm/dB)

- Sigmoid-Funktion:
$$\frac{1}{1 + e^{-(\omega_0 + \omega_1 \cdot x)}}$$

Methoden der Erklärbarkeit

Intrinsisch erklärbare Modelle (Whitebox)

- Lineare Regression
- Logistische Regression
- Entscheidungsbaum (klein)
- Vorteil:
 - Einfach verständlich
- Nachteil:
 - Eingeschränkt in Komplexität / Performance

Beispiele

Lineare Regression


- Bsp.: Vorhersage Mietpreis (MP) von Wohnung:
- $MP(DZ, L) = -1.5 \cdot DZ - 0.5 \cdot L + 1050 \text{ €}$
- → Merkmal DZ (Distanz zum Zentrum/km) und L (Lärm/dB) verringern Mietpreis.

Entscheidungsbaum:

- Bsp.: Titanic: „Wenn Sie weiblich waren und nicht 3. Klasse gereist sind, dann hätten Sie mit Wahrscheinlichkeit von 93 % überlebt.“

Kompromiss zwischen Interpretierbarkeit und Genauigkeit

Learning Techniques (today)



Für welche Methode sollte ich mich entscheiden?

Kompromiss zwischen Interpretierbarkeit und Genauigkeit

Für welche Anwendungen würden Sie ein vollständig erklärbares Modell verlangen?

- Netflix-Empfehlungen
- Kreditvergabe
- Krebsdiagnose
- Spamfilter
- autonome Fahrzeuge

Für welche Methode sollte ich mich entscheiden?

Intrinsisch erklärbare Modelle (Whitebox)

- Einsatz des Modells bei wirklich wichtigen Dingen (Medizin/Kriminalität/Job/...), müssen
 - die erlernten Regeln/Modelle für Menschen/Experten verständlich sein
 - und auch vor Gericht bestehen können

Post-hoc-Methoden (Blackbox-Erklärer)

- Nichtlineares Problem für das ein einfaches Modell keine gute Performance liefert

Lokale vs. globale Erklärbarkeit

Lokale Erklärbarkeit

- Warum hat das Modell diese eine Entscheidung getroffen?
- Fokus: einzelne Vorhersage (z. B. Kredit für Person X).
- Hilft Einzelpersonen
- Beispiel:
 - Kredit nicht erhalten, da Einkommen zu klein und letzter Kredit noch nicht zurückgezahlt


Globale Erklärbarkeit

- Wie funktioniert das Modell insgesamt?
- Fokus: generelle Regeln, Muster, Einflussgrößen.
- Hilft Entwickler*innen, Regulierungsbehörden oder Manager*innen, das Modell zu verstehen und zu verbessern.
- Beispiel:
 - Das Einkommen ist das wichtigste Merkmal, gefolgt von Merkmal ...

Lokale vs. globale Erklärbarkeit

Quelle: Introduction to Intelligent User Interfaces, Sarah Theres Völkel, LMU, 2020

Lokale Erklärbarkeit – eher schlechtes Beispiel, da es nichts erklärt




Source: mail.google.com

Entscheidungsbäume und Feature Importance

- Trainierter Entscheidungsbaum und Random Forest liefern Feature Importance zurück
- Desto größer der Wert der Importance eines Features, desto wichtiger ist es

Code:


- `importances = forest.feature_importances_`



Entscheidungsbäume und Feature Importance

Übung

- Ergänzen Sie im Notebook [02 feature importance student.ipynb](#) Code, der eine Visualisierung der Feature Importances wie im Bild rechts erstellt.
- Alle Hilfsmittel erlaubt.
- Was ist der UCI adult income Datensatz?
- Was ist der XGBoost Klassifikationsalgorithmus?



Fragen?


- Warum möchten wir, dass uns eine KI ihre Entscheidung erklärt?
 - Für wen ist die Erklärung?
- Was ist Erklärbare KI?
 - Erklärbarkeit
 - Interpretierbarkeit
- Intrinsisch erklärbare Machine Learning Modelle

Lernraum III

Explainable AI (XAI) – Erklärbare KI

- Warum möchten wir, dass uns eine KI ihre Entscheidung erklärt?
 - Für wen ist die Erklärung?
- Was ist Erklärbare KI?
- Intrinsisch erklärbare Modelle
- **Post-hoc-Methoden**
 - **LIME**
 - **SHAP**
- Erklärungen heutiger Systeme

Methoden der Erklärbarkeit



Post-hoc-Methoden (Blackbox-Erklärer)

Ein zweites Modell ist erforderlich, das Erklärungen für das trainierte Blackbox Modell liefert

- Ziel: Erklärung ohne Zugriff auf die Struktur des ersten Modells
- Methoden:
 - LIME
 - SHAP
 - Saliency Maps

Post-hoc-Methoden (Blackbox-Erklärer)

Lokale modellagnostische Post-hoc-Methoden

- LIME
 - Lokale Erklärbarkeit

Lokale und globale modellagnostische Post-hoc-Methoden


- SHAP
 - Lokale und globale Erklärbarkeit

Post-hoc-Methoden (Blackbox-Erklärer)

LIME (Local Interpretable Model-agnostic Explanations)

LIME: Lokale Erklärbarkeit für Blackbox-Modelle

- LIME erzeugt eine lineare Approximation rund um eine konkrete Vorhersage
- Datenpunkte sind Variationen des Datenpunktes für den wir eine Erklärung haben möchten
- Variationen werden durch Blackbox-Modell klassifiziert
- Idee: Verhalten des Blackbox-Modells lokal erklären, nicht global verstehen



Post-hoc-Methoden (Blackbox-Erklärer)

LIME (Local Interpretable Model-agnostic Explanations)

Intuition

- 1) Divide input into **interpretable components** that “make sense” to humans (e.g. words or parts of image)



Original Image



Interpretable
Components

Superpixel

Post-hoc-Methoden (Blackbox-Erklärer)

LIME (Local Interpretable Model-agnostic Explanations)

Intuition

- 1) Divide input into **interpretable components** that “make sense” to humans (e.g. words or parts of image)
- 2) **Generate random perturbations** of data set



Post-hoc-Methoden (Blackbox-Erklärer)

LIME (Local Interpretable Model-agnostic Explanations)

Intuition

- 1) Divide input into **interpretable components** that “make sense” to humans (e.g. words or parts of image)
- 2) **Generate random perturbations** of data set
- 3) **Predict classes** for these **perturbations** using your black box model


Perturbed Instances	P(tree frog)
	 0.85
	 0.00001
	 0.52

Post-hoc-Methoden (Blackbox-Erklärer)

LIME (Local Interpretable Model-agnostic Explanations)

Intuition

- 1) Divide input into **interpretable components** that “make sense” to humans (e.g. words or parts of image)
- 2) **Generate random perturbations** of data set
- 3) **Predict classes for these perturbations** using your black box model
- 4) **Weight** the perturbations (importance) according to their proximity to the original input.




Post-hoc-Methoden (Blackbox-Erklärer)

LIME (Local Interpretable Model-agnostic Explanations)

Intuition

- 1) Divide input into **interpretable components** that “make sense” to humans (e.g. words or parts of image)
- 2) **Generate random perturbations** of data set
- 3) **Predict classes** for these **perturbations** using your black box model
- 4) **Weight** the perturbations (importance) according to their proximity to the original input.
- 5) **Train a weighted, interpretable model** on the dataset with the variations.



Post-hoc-Methoden (Blackbox-Erklärer)

LIME (Local Interpretable Model-agnostic Explanations)

Intuition

- 1) Divide input into **interpretable components** that “make sense” to humans (e.g. words or parts of image)
- 2) **Generate random perturbations** of data set
- 3) **Predict classes for these perturbations** using your black box model
- 4) **Weight** the perturbations (importance) according to their proximity to the original input.
- 5) **Train a weighted, interpretable model** on the dataset with the variations.
- 6) Explain the prediction by **interpreting the local model**.
→ Wir schauen uns die Superpixels an, die zu den größten Gewichte gehören



Post-hoc-Methoden (Blackbox-Erklärer)

LIME (Local Interpretable Model-agnostic Explanations)

Practical Example:

https://colab.research.google.com/github/arteagac/arteagac.github.io/blob/master/blog/lime_image.ipynb

Post-hoc-Methoden (Blackbox-Erklärer)

LIME (Local Interpretable Model-agnostic Explanations)

Wie funktioniert LIME?

- Auswahl eines konkreten Datenpunkts („Warum diese Entscheidung?“)
- Erzeugung von leichten Variationen dieses Datenpunkts („Perturbationen“)
- Vorhersage mit dem Blackbox-Modell für jede Variation
- Training eines einfachen Modells (z. B. lineare Regression) mit diesen lokalen Variationen
- Visualisierung der Feature-Gewichte für die Erklärung

Post-hoc-Methoden (Blackbox-Erklärer)

LIME (Local Interpretable Model-agnostic Explanations)

2. Notebook-Aufgabe LIME & SHAP für tabellarische Daten.

Öffnen Sie `01_LIME_SHAP_tabular.ipynb` in Google Colab und führen Sie das gesamte Notebook aus. Beantworten Sie anschließend:

- (a) Was ist der “UCI adult income dataset”? Was soll vorhergesagt werden? Was sind die Merkmale?
- (b) Welche Klasse wird für den Datenpunkt 0 des Testdatensatzes vorhergesagt? Was sind laut LIME die 2-3 wichtigsten Merkmale, die zu dieser Entscheidung geführt haben? Welche Werte haben diese? Macht es Sinn, dass diese Merkmale die wichtigsten sind und andere unwichtig?
- (c) Welche Klasse wird für den Datenpunkt 100 des Testdatensatzes vorhergesagt? Was sind laut LIME die 2-3 wichtigsten Merkmale, die zu dieser Entscheidung geführt haben? Welche Werte haben diese? Macht es Sinn, dass diese Merkmale die wichtigsten sind und andere unwichtig?

[Link zu Notebook](#)

Post-hoc-Methoden (Blackbox-Erklärer)


LIME (Local Interpretable Model-agnostic Explanations)

3. Feature Importance für Entscheidungsbäume.

Öffnen Sie `02_feature_importance.ipynb` in Google Colab. Beantworten Sie anschließend:

- (a) Was sind die wichtigsten drei Features bezüglich der Feature Importance?
- (b) Vergleichen Sie die Ergebnisse mit LIME. Was fällt auf?

[02_feature_importance_student.ipynb](#)



Post-hoc-Methoden (Blackbox-Erklärer)

LIME (Local Interpretable Model-agnostic Explanations)

4. Notebook-Aufgabe LIME (Text).

Öffnen Sie `03_LIME_nlp.ipynb` und führen Sie das Notebook vollständig aus. Beantworten Sie anschließend:

- (a) Was ist TF-IDF?
- (b) Welche drei Wörter haben die Vorhersage für den Text mit der ID 83 am stärksten beeinflusst? Wo stehen diese Wörter im Text? Haben die Wörter etwas mit der vorhergesagten Klasse zu tun? Welche Klasse wurde vorhergesagt?
- (c) Probieren Sie ein anderes Dokument aus dem Testdatensatz aus und berichten Sie über Ihre Ergebnisse.
- (d) Diskutieren Sie, inwiefern die Erklärung für eine *nicht-technische* Nutzergruppe brauchbar ist. Was würden Sie an der Darstellung ändern?

[03_LIME_nlp.ipynb](#)

TF-IDF (Term Frequency – Inverse Document Frequency)

Idee

- Nicht jedes Wort ist gleich informativ:
 - Häufige Wörter wie „the“, „and“ oder „is“ kommen in vielen Dokumenten vor und tragen wenig zur Unterscheidung bei.
 - Seltenerer Wörter wie „nasa“, „galaxy“ oder „rendering“ sind oft aussagekräftiger.
- TF-IDF gewichtet daher Wörter nach ihrer Bedeutung für ein Dokument innerhalb einer Dokumentensammlung.
- Term Frequency (TF)
 - Misst, wie häufig ein Wort t in einem Dokument d vorkommt.
 - $TF(t,d)$
 - Je häufiger ein Wort im Dokument erscheint, desto größer sein TF-Wert.

TF-IDF (Term Frequency – Inverse Document Frequency)

Inverse Document Frequency (IDF)

- Misst, wie selten ein Wort in der gesamten Dokumentensammlung ist.
 - $IDF(t) = \log(N / df(t))$
- Mit
 - N: Anzahl aller Dokumente
 - $df(t)$: Anzahl der Dokumente, die das Wort t enthalten
- Eigenschaften:
 - häufige Wörter → kleine IDF
 - seltene Wörter → große IDF
- TF-IDF-Gewicht
 - $TF-IDF(t,d) = TF(t,d) \times IDF(t)$
- Hohe Werte erhalten Wörter, die im aktuellen Dokument häufig vorkommen, aber in der Gesamtheit der Dokumente selten sind.

TF-IDF (Term Frequency – Inverse Document Frequency)

Ergebnis

Jedes Dokument wird als numerischer Merkmalsvektor dargestellt, dessen Komponenten die TF-IDF-Gewichte der Wörter enthalten. Diese Vektoren können anschließend von Machine-Learning-Verfahren weiterverarbeitet werden.

Nachteile von TF-IDF:

- Reihenfolge von Wörter wird nicht berücksichtigt (semantische Bedeutung geht verloren)
- „Vor der Bank sitze ich auf einer Bank.“ - Ambiguität von „Bank“ wird nicht erkannt
 - $\rightarrow \text{TF}(\text{„Bank“}) = 2$

Post-hoc-Methoden (Blackbox-Erklärer)


LIME (Local Interpretable Model-agnostic Explanations)

Vorteile

- Modellunabhängig
 - funktioniert mit beliebigen Blackbox-Modelle (z. B. Random Forests, Deep Learning)
- Erzeugt verständliche Erklärungen
- Flexibel einsetzbar
 - Textklassifikation, Bildklassifikation, tabellarische Daten

Grenzen

- Ergebnisse können instabil sein (bei ähnlichem Input → andere Erklärung)
- Nur lokal interpretierbar (Lokale Erklärbarkeit)
- Erklärungen nicht immer eindeutig verständlich für Laien



Post-hoc-Methoden (Blackbox-Erklärer)

SHAP (SHapley Additive exPlanations) - Motivation

- Projektgruppe:
 - Alice
 - Bob
 - Carol
- Projektpunktzahl: 90 %
- Frage:
 - Wie teilen wir den Erfolg fair auf?
- Genau dieselbe Idee nutzt SHAP für Features.

Post-hoc-Methoden (Blackbox-Erklärer)

SHAP (SHapley Additive exPlanations)

SHAP: Fairness und Relevanz durch Spieltheorie


- SHAP basiert auf Shapley-Werten aus der Spieltheorie
 - Der Shapley-Wert ist eine Methode zur Zuweisung von Auszahlungen an Spieler in Abhängigkeit von ihrem Beitrag zur Gesamtauszahlung. Die Spieler kooperieren in einer Koalition und erhalten aus dieser Kooperation einen bestimmten Gewinn.
 - Analogie:
 - Merkmal = Spieler; Gewinn = korrekte Vorhersage
- Jedes Merkmal liefert einen Beitrag zur Vorhersage – wie Spieler zum Teamerfolg
- Vorgehensweise:
 - Es wird je ein Merkmal weggelassen und mit den anderen Merkmalen je ein Modell trainiert
 - Die Vorhersagen der verschiedenen Modelle werden linear kombiniert (ähnlich zu LIME – dort hatten wir viele Vorhersagen mit dem gleichen Modell, hier haben wir je eine Vorhersage mit vielen Modellen)

Post-hoc-Methoden (Blackbox-Erklärer)

SHAP (SHapley Additive exPlanations)

Eine SHAP-Erklärung lesen

- Anwendung
 - Vorhersage ob man Kredit zurückzahlen wird (negative Klasse: 0) oder nicht (positive Klasse: 1)
- Merkmale
 - *diff_firstrepaiddate_firstduedate_mean*: Durchschnittliche Verzögerung bei der ersten Zahlung früherer Kredite
 - GPS-Koordinaten des Wohnorts
 - Alter
 - ...




Post-hoc-Methoden (Blackbox-Erklärer)

SHAP (SHapley Additive exPlanations)

Eine SHAP-Erklärung lesen

- SHAP Wert (numerische Approximation des Shapley Wertes): Wie stark beeinflusst jedes Feature die Vorhersage?
- Hier: SHAP Summary Plot
- Merkmale sortiert nach SHAP Wert
- Für jeden Datenpunkt (bspw. aus Trainingsdatensatz) bestimmen wir den SHAP Wert mittels Vorhersage der trainierten Modelle
- Farbkodierung: rot = hoher Featurewert, blau = niedriger
- Hier erhalten wir eine globale Erklärung




Post-hoc-Methoden (Blackbox-Erklärer)

SHAP (SHapley Additive exPlanations)

Eine SHAP-Erklärung lesen

▪ Lokale Erklärbarkeit

- Hier: SHAP Force Plot
- Farbkodierung:
 - rot = Kräfte, die zur positiven Klasse führen
 - blau = Kräfte, die zur negativen Klasse führen



Post-hoc-Methoden (Blackbox-Erklärer)

SHAP (SHapley Additive exPlanations)

Vorteile

- Basiert auf Spieltheorie
- Modellagnostisch: funktioniert für sehr viele ML-Modelle
- Man erhält Einsicht sowohl für die lokale als auch globale Erklärbarkeit

- Beispiel: s. Übung

Herausforderungen

- Komplexität / Rechenaufwand (v. a. bei Deep Learning)
- Interpretation für Endnutzer*innen kann erklärungsbedürftig sein
- Nur eingeschränkt visuell verständlich

Grenzen von XAI

Können Erklärungen irreführend sein?


- Beispiele:
 - LIME kann instabil sein.
 - SHAP ist nur eine Approximation.
 - Erklärung $\neq$ tatsächlicher Entscheidungsprozess.
 - Eine plausible Erklärung kann falsch sein.

- Wichtig: Eine Erklärung ist selbst ein Modell.

Erklärungen heutiger Systeme

Quelle: Introduction to Intelligent User Interfaces, Sarah Theres Völkel, LMU, 2020

“Warum”
Erklärung



Source: www.netflix.com

Transparenz
Vertrauen
Effektivität
Überzeugungskraft

“Sicherheit”
Erklärung

Kunden, die diesen Artikel gekauft haben, kauften auch



Source: www.amazon.de


Erklärungen heutiger Systeme

Quelle: Introduction to Intelligent User Interfaces, Sarah Theres Völkel, LMU, 2020

“Warum”
Erklärung



Transparenz
Überprüfbarkeit



“Inputs”
Erklärung


Zufriedenstellung

Source: www.facebook.com

Diskussion

Quelle: Introduction to Intelligent User Interfaces, Sarah Theres Völkel, LMU, 2020

Wie würden Sie die **Erklärung von Netflix verbessern**, warum ein bestimmter Film empfohlen wurde?



Source: www.netflix.com

Wie erklärt man eigentlich ChatGPT?

Herausforderung

- LLMs bestehen aus Milliarden von Parametern und sind weitgehend Black-Box-Modelle.
- Fragen:
 - Warum wurde genau diese Antwort erzeugt?
 - Welche Trainingsdaten waren relevant? Welches Wissen wurde genutzt?
 - Wann kann ich der Antwort vertrauen?
- XAI für LLMs ist aktuelle Forschung
- Vertrauen Sie einem LLM, das 98 % korrekte Antworten liefert, aber seine Entscheidungen nicht erklären kann?

Zusammenfassung

- XAI ist nicht nur eine technische Ergänzung, sondern zentral für menschenzentrierte Gestaltung.
- Wichtig ist nicht nur ob ein Modell erklärt, sondern wie, für wen und zu welchem Zweck.
- Sie können interpretierbare Modelle nutzen ...
 - Lineare/Logistische Regression, kleine Entscheidungsbäume, ...
- ... oder BlackBox-Modelle versuchen zu erklären mit ...
 - LIME
 - SHAP
 - ...

Je leistungsfähiger die Modelle werden, desto schwieriger wird ihre Erklärbarkeit.

Nächste Vorlesung und Fragen

- Data Augmentation und Objektdetektion und -segmentierung
- Fragen?